

Univerzitet u Beogradu - Elektrotehnički fakultet

Katedra za signale i sisteme



Poređenje metoda klasifikacije za detekciju lažnih transakcija kreditnim karticama

Kandidat
Jelena Cicvarić 2022/0005

Mentor
Prof. dr Željko Đurović, redovni profesor

Beograd, *jul* 2026. godine

Sadržaj

1 UVOD 4

2 Testiranje hipoteza 6

2.1 Bajesovo pravilo odlučivanja minimalne greške 6

2.2 Bajesovo pravilo minimalne cene 8

2.3 Neyman-Pearsonov test 9

2.4 Minimax test 10

3 Metode klasifikacije 11

3.1 Parametarske metode klasifikacije 11

3.1.1 Bajesovski linearni klasifikator 11

3.1.2 Kvadratni klasifikator 13

3.2 Neparametarske metode klasifikacije 14

3.2.1 Parzenova estimacija 14

3.2.2 Metoda k najbližih suseda (KNN) 15

4 Support Vector Machines (SVM) 18

4.1 Matematičke osnove 18

4.1.1 Vektori i skalarni proizvod 18

4.1.2 Hiperravan i linearna separabilnost 19

4.2 Optimalna hiperravan i margina 20

4.2.1 Problem poređenja hiperravni 20

4.2.2 Funkcionalna margina 20

4.2.3 Geometrijska margina 20

4.2.4 Optimalna hiperravan 21

4.3 Formulacija optimizacionog problema 22

4.3.1 Primarni optimizacioni problem 22

4.3.2 Lagranževi multiplikatori i Lagranževa funkcija 23

4.3.3 Wolfe-ov dualni problem 23

4.3.4 KKT uslovi i potporni vektori 24

4.4 Meka margina 25

4.4.1 Ograničenja tvrde margine 25

4.4.2 Slack promenljive 25

4.4.3 Uloga hiperparametra C 26

4.5 Kernel trik 27

4.5.1 Motivacija 27

4.5.2 Kernelska funkcija i kernel trik 27

4.5.3 Tipovi kernelskih funkcija ... 28
4.6 SMO algoritam ... 29
4.6.1 Motivacija ... 29
4.6.2 Osnovna ideja ... 29
4.6.3 Izbor multiplikatora ... 29
4.6.4 Analitičko rešenje za par multiplikatora ... 30
4.7 Zaključci o SVM metodologiji ... 30
5 Primena klasifikacionih metoda na problem detekcije lažnih transakcija kreditnim karticama ... 31
5.1 Opis problema i skupa podataka ... 31
5.2 Priprema podataka ... 32
5.2.1 Predobrada ... 32
5.2.2 Podela na skup za obučavanje i skup za testiranje ... 32
5.2.3 Skaliranje ... 32
5.3 Vizualizacija podataka ... 33
5.4 Implementacija i opis klasifikacionih modela ... 33
5.4.1 Linearni SVM klasifikator ... 34
5.4.2 RBF SVM klasifikator ... 34
5.4.3 Linearni SVM sa SMOTE balansiranjem ... 34
5.4.4 Klasifikator sa Bajesovim kriterijumom minimalne cene ... 35
5.4.5 KNN klasifikator ... 35
6 Rezultati ... 36
6.1 Linearni SVM klasifikator ... 36
6.2 RBF SVM klasifikator ... 37
6.3 SVM + SMOTE klasifikator ... 38
6.4 Klasifikator sa Bajesovim kriterijem minimalne cene ... 39
6.5 KNN klasifikator ... 41
6.6 Uporedno poređenje modela ... 42
7 Zaključak ... 44
8 Literatura ... 45

1 UVOD

Svaki put kada platimo karticom, negde u pozadini sistem za svega nekoliko milisekundi odlučuje da li je ta transakcija legitimna ili ne. Iza te odluke stoje algoritmi klasifikacije koji moraju biti dovoljno pouzdani da zaštite korisnike, a opet dovoljno precizni da ne blokiraju svaku drugu legitimnu kupovinu. Kada sam tražila temu za diplomski rad, upravo me je privuklo pitanje kako banke zapravo rešavaju ovaj problem i koliko su metode koje smo učili na predmetu Prepoznavanje oblika primenjive na nešto tako konkretno.

Problem detekcije lažnih transakcija kreditnim karticama u osnovi je problem binarne klasifikacije, ali sa jednim specifičnim izazovom koji ga čini znatno težim od standardnih primera iz udžbenika. Lažne transakcije su izuzetno retke- u skupu podataka korišćenom u ovom radu čine svega 0.17% od ukupnog broja transakcija. To znači da model koji bi svaku transakciju proglasio legitimnom postiže tačnost od 99.83%, a pritom ne bi otkrio nijednu prevaru. Zbog toga se standardna metrika tačnosti ovde ne može koristiti, a algoritmi koji nisu posebno prilagođeni ovom problemu gotovo uvek zanemaruju manjinsku klasu.

Drugi izazov vezan je za prirodu podataka. Iz razloga zaštite privatnosti, obeležja transakcija u javno dostupnim skupovima podataka anonimizovana su primenom analize glavnih komponenti, što znači da ne znamo šta konkretno obeležja V1–V28, o kojima će kasnije biti više reči, predstavljaju. To onemogućava bilo kakvo oslanjanje na domensko znanje i čini problem isključivo statističkim.

U literaturi su ispitivani različiti pristupi ovom problemu. Vladimir Vapnik, koji je još 1963. postavio teorijske temelje SVM metode, a zatim sa Cortes-om 1995. uveo meku marginu [1], dao je jedan od najznačajnijih doprinosa oblasti klasifikacije koji se direktno primenjuje i u ovom kontekstu. Detaljan i pristupačan pregled SVM metodologije, koji je poslužio kao osnova za poglavlje 4 ovog rada, dat je u knjizi *Support Vector Machines Succinctly* autora Alexandre Kowalczyk-a [2]. Što se tiče neparametarskih metoda, Cover i Hart su još 1967. teorijski pokazali da KNN u graničnom slučaju postiže grešku ne veću od dvostruke Bajesove [6], ali u praksi su njene performanse izrazito zavisne od lokalne strukture konkretnog skupa podataka.

Problem neuravnoteženosti klasa u literaturi se rešava na dva načina. Prvi se zasniva na modifikaciji skupa podataka, potiskivanjem uzorkovanja većinske klase ili sintetičkim generisanjem novih primera manjinske klase tehnikom SMOTE [3], koju su predložili Chawla et al. (2002). Drugi pravac se zasniva na modifikaciji kriterijuma odlučivanja eksplicitnim ponderisanjem klasa ili pomeranjem praga odlučivanja prema odnosu cena grešaka, jer propuštena prevara i lažna uzbuna nemaju isti trošak. U ovom radu ispitana su oba pravca: ponderisanje klasa kroz parametar class_weight kod linearnog SVM-a, sintetičko generisanje primera kroz SMOTE i pomeranje praga kroz Bajesov kriterijum minimalne cene.

SVM sam izabrala kao centralnu metodu, jer nudi nešto što većina klasifikatora nema, a to je teorijska garancija da pronalazi granicu odluke sa maksimalnom marginom, ne samo neku koja radi na trening podacima. Na skupu gde je lažnih transakcija svega 492 od skoro 285.000, to nije nevažno. Pored toga, kernel trik omogućava nelinearnu granicu bez eksplicitne transformacije podataka, što je relevantno jer je PCA vizualizacija sugerisala da

klase nisu linearno separabilne u originalnom prostoru, o čemu će biti više reči u poglavlju 5.4.

Cilj ovog rada je da poredi pet metoda klasifikacije na problemu detekcije lažnih transakcija i da ispita kako svaka od njih reaguje na neuravnoteženost klasa. Konkretno, ispituju se tri varijante SVM klasifikatora, Bajesov klasifikator sa kriterijumom minimalne cene i KNN algoritam. Pitanja na koja rad pokušava da odgovori su: koja metoda postiže najbolji balans između otkrivenih prevara i lažnih uzbuna, da li SMOTE balansiranje donosi merljivo poboljšanje u odnosu na ponderisanje klasa i koliko su rezultati KNN metode pouzdani s obzirom na specifičnosti skupa podataka i načina uzorkovanja.

Rad je organizovan na sledeći način. Poglavlje 2 opisuje statističku osnovu odlučivanja kroz četiri pristupa testiranju hipoteza. Poglavlje 3 prikazuje metode klasifikacije koje su korišćene ili koje predstavljaju teorijski okvir za razumevanje primenjenih algoritama. Poglavlje 4 detaljno opisuje SVM metodologiju. Poglavlje 5 opisuje skup podataka, pripremu i implementaciju svih pet modela. Poglavlje 6 prikazuje i analizira rezultate, a poglavlje 7 donosi zaključke.

2 Testiranje hipoteza

Osnovni cilj klasifikacije jeste donošenje odluke kojoj klasi posmatrani uzorak pripada, na osnovu izmerenog vektora obeležja X. Pod testiranjem hipoteza podrazumevaju se metode koje rešavaju ovaj problem kada su poznate uslovne funkcije gustine verovatnoće klasa. Posmatramo slučaj dveju klasa ω_1 i ω_2 sa apriornim verovatnoćama P_1 i P_2 i uslovnim funkcijama gustine $f_1(X) = f(X/\omega_1)$ i $f_2(X) = f(X/\omega_2)$.

Zavisno od informacije koja je dostupna pri projektovanju i od cilja koji se želi postići, razvijeno je nekoliko pristupa testiranju hipoteza. Bajesovo pravilo minimalne greške optimalno je u smislu ukupne verovatnoće greške, ali zahteva poznavanje apriornih verovatnoća klasa. Kada greške nisu jednako skupe, prirodno uopštenje je Bajesov kriterijum minimalne cene. Neyman-Pearsonov test koristan je kada je jedna vrsta greške strogo ograničena, dok minimax pristup štiti performanse klasifikatora u uslovima kada apriorne verovatnoće nisu poznate ili se menjaju. U nastavku su opisani svi navedeni pristupi.

2.1 Bajesovo pravilo odlučivanja minimalne greške

Aposteriorne verovatnoće $q_i(X) = Pr(\omega_i/X)$ sračunavaju se primenom Bajesove teoreme:

$$q_i(X) = \frac{f_i(X)P_i}{f_1(X)P_1 + f_2(X)P_2}$$

Pošto je zajednički imenilac pozitivan za obe klase, pravilo odlučivanja se svodi na poređenje proizvoda apriornih verovatnoća i uslovnih gustina:

$$P_1 f_1(X) > P_2 f_2(X) \Rightarrow X \in \omega_1$$
$$P_1 f_1(X) < P_2 f_2(X) \Rightarrow X \in \omega_2$$

Uvodi se količnik verodostojnosti:

$$l(X) = \frac{f_1(X)}{f_2(X)}$$

koji se poredi sa pragom $\frac{P_1}{P_2}$. Primenom negativnog prirodnog logaritma dobija se diskriminaciona funkcija $h(X) = -ln(l(X))$, a pravilo odlučivanja prelazi u:

$$h(X) < \ln\frac{P_1}{P_2} \Rightarrow X \in \omega_1$$
$$h(X) > \ln\frac{P_1}{P_2} \Rightarrow X \in \omega_2$$

U specijalnom slučaju jednakih apriori verovatnoća $P_1 = P_2 = 0.5$, prag je nula. Ovo pravilo minimizuje ukupnu verovatnoću greške, tj. Bajesovu grešku ε, koja se računa kao:

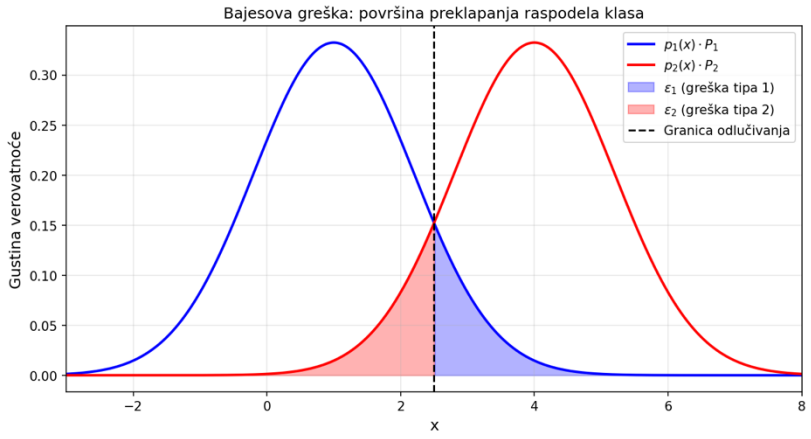
$$\varepsilon = P_1\varepsilon_1 + P_2\varepsilon_2,$$

gde su ε_1 i ε_2 verovatnoće greške prvog i drugog tipa, respektivno.

Za slučaj normalnih raspodela sa kovarijacionim matricama Σ_i i sredinama M_i, diskriminaciona funkcija je kvadratna po X. Kada su kovarijacione matrice jednake ($\Sigma_1 = \Sigma_2 = \Sigma$), granica odlučivanja postaje linearna funkcija po X, što odgovara poznatom linearnom diskriminantu.

Geometrijski, Bajesova greška odgovara površini preklapanja između raspodela dveju klasa, tj. onoj površini ispod krive $f_1(X)$ koja "upada" u region klase ω_2 i obrnuto. Što su klase više razdvojene, ta površina je manja i greška je manja. Na konkretnom skupu podataka korišćenom u ovom radu, lažne transakcije se u PCA prostoru preklapaju sa legitimnim, što znači da je Bajesova greška nenulta i da je određeni broj pogrešnih klasifikacija neizbežan bez obzira na metodu.

Slika 2-1 ilustruje ovu interpretaciju- osenčene površine prikazuju Bajesovu grešku.



Slika 2-1 Preklapanje raspodela klasa kod Bajesove greške

Važno je napomenuti da Bajesovo pravilo minimalne greške, uprkos svojoj optimalnosti, u praksi zahteva egzaktno poznavanje uslovnih funkcija gustine verovatnoće klasa. U većini realnih problema ove funkcije nisu poznate- dostupan je samo skup obučavajućih uzoraka. Zbog toga se u praksi pristupa proceni tih funkcija, bilo parametarskim metodama (opisanim u poglavlju 3.1) bilo neparametarskim (poglavlje 3.2). Veza između testiranja hipoteza i metoda klasifikacije opisanih u nastavku leži upravo u tome: strukturau klasifikatora dobijamo iz teorije odlučivanja, dok se procene funkcija gustine dobijaju iz podataka.

2.2 Bajesovo pravilo minimalne cene

U praksi minimizacija verovatnoće greške nije uvek najprikladniji kriterijum, jer greška klasifikacije nije jednako skupa za sve klase. Uvode se cene odlučivanja c_{ij}, što označava cenu odluke $X \in \omega_i$ kada zapravo $X \in \omega_j$.

Uslovna cena odluke $X \in \omega_i$ pri datom mernom vektoru X je:

$$r_i(X) = c_{i1}q_1(X) + c_{i2}q_2(X)$$

Pravilo odlučivanja minimalne cene bira klasu sa manjim uslovnim rizikom:

$$r_1(X) < r_2(X) \Rightarrow X \in \omega_1,$$

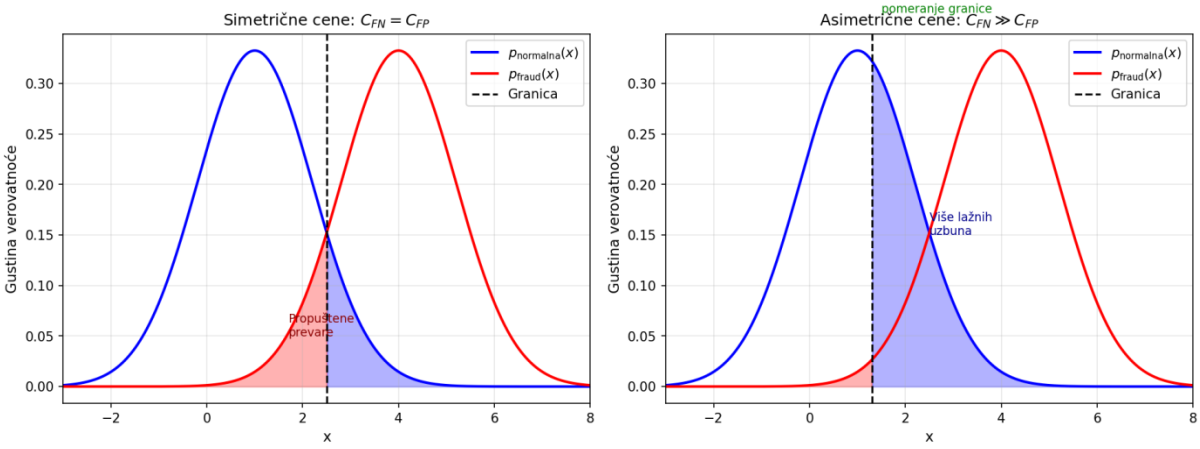
što, nakon uvrštavanja Bajesove teoreme, daje:

$$\frac{f_1(X)}{f_2(X)} > \frac{(c_{12}-c_{22})P_2}{(c_{21}-c_{11})P_1} \Rightarrow X \in \omega_1.$$

Ovo pravilo je strukturno identično pravilu minimalne greške, ali se razlikuje u vrednosti praga. U slučaju simetričnih cena ($c_{21} - c_{11} = c_{12} - c_{22}$) oba pravila su ekvivalentna. Povećanje cene c_{21} pomera granicu odlučivanja dalje od klase ω_1, jer je kazna za pogrešnu klasifikaciju oblika iz ω_1 veća.

U kontekstu detekcije lažnih transakcija, ovaj pristup je posebno relevantan. Propuštena prevara (lažno negativan rezultat) ima znatno veće posledice nego lažna uzbuna (lažno pozitivan rezultat). Kroz odnos cena $\frac{C_{FN}}{C_{FP}}$, ova asimetrija se može iskoristiti da se granica odlučivanja pomeri u korist otkrivanja prevara. Upravo ovaj princip korišćen je pri implementaciji Bajesovog klasifikatora u eksperimentalnom delu ovog rada (poglavlje 5.4.4).

Slika 2-2 prikazuje kako se granica odlučivanja pomera kada propuštena prevara postaje skuplja od lažne uzbune.



Slika 2-2 Uticaj odnosa cena grešaka na granicu odlučivanja. Levo: simetrične cene daju standardnu granicu. Desno: kada je C_FN ≫ C_FP, granica se pomera u korist klase prevara, što povećava broj detektovanih prevara po cenu većeg broja lažnih uzbuna.

2.3 Neyman-Pearsonov test

Neyman-Pearsonov test polazi od drugačijeg cilja: minimizovati grešku prvog tipa ε_1 uz ograničenje da greška drugog tipa ne prelazi zadatu vrednost $\varepsilon_2 = \varepsilon_0$. Kriterijumska funkcija koja se minimizuje je:

$$r = \varepsilon_1 + \mu(\varepsilon_2 - \varepsilon_0),$$

gde je μ Lagranžev multiplikator. Minimizacijom po oblastima odlučivanja dobija se pravilo:

$$\frac{f_1(X)}{f_2(X)} > \mu \Rightarrow X \in \omega_1, \frac{f_1(X)}{f_2(X)} < \mu \Rightarrow X \in \omega_2.$$

Dakle, i Neyman-Pearsonov test je test količnika verodostojnosti, s tim što je razlika u odnosu na Bajesov pristup u načinu određivanja praga μ. Prag se ne dobija iz apriornih verovatnoća, već iz uslova:

$$\varepsilon_2 = \int_{L_1} f_2(X)\, dX = \varepsilon_0.$$

Kako se ova relacija po pravilu ne može analitički rešiti po μ, parametar se određuje numerički izračunavanjem ε_2 za niz vrednosti μ i interpolacijom do željene ε_0. U tu svrhu koristi se procena funkcije gustine verovatnoće diskriminacione funkcije $h(X)$ za odbirke iz druge klase, najčešće metodom histograma.

Neyman-Pearsonov test ima posebnu vrednost u domenima gde zakon propisuje gornju granicu za određenu vrstu greške. Na primer, u medicinskoj dijagnostici može biti prihvatljivo da se greška drugog tipa (propuštena bolest) drži ispod 5%, dok greška prvog tipa nije strogo ograničena. Analogno tome, u sistemima za detekciju prevara može se zahtevati da se ne propusti više od određenog procenta lažnih transakcija, pri čemu je broj lažnih uzbuna manje važan. Ključna praktična razlika u odnosu na Bajesov pristup jeste da Neyman-Pearsonov test ne zahteva poznavanje apriornih verovatnoća klasa, već je dovoljno poznavati funkciju gustine diskriminacione funkcije za jednu od klasa.

U ovom radu Neyman-Pearsonov test nije direktno primenjen, ali njegova logika da se jedna vrsta greške eksplicitno drži pod kontrolom motiviše izbor metrika evaluacije u poglavlju 6. Umesto tačnosti, korišćeni su odziv i preciznost koji direktno mere grešku drugog tipa (propuštene prevare) i grešku prvog tipa (lažne uzbune), što je u duhu ovog pristupa.

2.4 Minimax test

Bajesov test i test minimalne cene zahtevaju poznavanje apriornih verovatnoća P_1 i P_2, koje u praksi često nisu poznate ili se menjaju tokom vremena. Minimax test projektuje pravilo odlučivanja koje minimizuje maksimalni mogući rizik po svim vrednostima $P_1 \in [0,1]$.

Rizik r je, za fiksne granice odlučivanja, linearna funkcija od P_1. Minimax rešenje odgovara onoj vrednosti P_1 za koju je $r_{opt}(P_1)$ maksimalan, tj. stacionarnoj tački krive optimalnog rizika:

$$\frac{dr_{opt}(P_1)}{dP_1} = 0$$

Granice odlučivanja se biraju tako da koeficijent uz P_1 u izrazu za ukupan rizik bude jednak nuli:

$$\int_{L_2}(c_{21} - c_{11})f_1(X)\,dX - \int_{L_1}(c_{12} - c_{22})f_2(X)\,dX = c_{21} - c_{22}.$$

U specijalnom slučaju simetričnih cena ($c_{11} = c_{22}$, $c_{12} = c_{21}$), minimax pravilo vodi do izjednačavanja grešaka oba tipa: $\varepsilon_1 = \varepsilon_2$. Naziv dolazi od toga što se bira tačka maksimuma krive optimalnog rizika, što je najgori slučaj po pitanju rizika kako bi se minimizovala šteta od eventualnih promena apriorne verovatnoće.

Minimax test nije primenjen u eksperimentalnom delu ovog rada jer su apriorne verovatnoće klasa poznate i stabilne- iz skupa podataka direktno se vidi da lažne transakcije čine 0.17% ukupnog broja. Kada su apriorne verovatnoće poznate, Bajesov pristup je prirodniji izbor jer daje bolje performanse. Minimax bi bio relevantan u scenariju gde se taj procenat menja tokom vremena, na primer ako bi se model trenirao na podacima iz jednog perioda a primenjivao u drugom kada je učestalost prevara drugačija.

Sva četiri opisana pristupa zasnivaju se na istoj ideji- testu količnika verodostojnosti i razlikuju se samo u tome kako određuju prag odlučivanja.

3 Metode klasifikacije

Kada uslovne funkcije gustine verovatnoće klasa nisu poznate unapred, problem klasifikacije se ne može rešiti direktnom primenom testova odlučivanja opisanih u prethodnom poglavlju. Umesto toga, klasifikator se projektuje na osnovu raspoloživog skupa obučavajućih uzoraka. Zavisno od toga da li se pretpostavlja određeni oblik raspodele podataka ili ne, metode klasifikacije dele se na parametarske i neparametarske.

Parametarske metode su efikasne kada je pretpostavka o obliku raspodele opravdana i kada raspolažemo relativno malim brojem uzoraka- procena nekoliko parametara je stabilnija od procene cele funkcije. Sa druge strane, kada raspodele klasa nisu normalne, kada su višemodalne ili kada je broj uzoraka dovoljno velik, neparametarski pristupi postaju prirodniji izbor jer direktno uče iz podataka bez ikakvih pretpostavki. U ovom radu oba pravca su relevantna- linearni SVM se konceptualno oslanja na parametarski pristup kroz linearnu granicu odluke, dok KNN direktno primenjuje neparametarsku estimaciju gustine.

3.1 Parametarske metode klasifikacije

Parametarske metode polaze od pretpostavke da podaci iz svake klase slede određenu raspodelu, najčešće normalnu, i da je zadatak klasifikatora da na osnovu obučavajućeg skupa proceni parametre te raspodele. Kada su raspodele normalne sa poznatim parametrima $f_1(X) \sim N(M_1, \Sigma_1)\ i\ f_2(X) \sim N(M_2, \Sigma_2)$, diskriminaciona funkcija dobija kvadratnu formu:

$$h(X) = \frac{1}{2}(X - M_1)^T \Sigma_1^{-1}(X - M_1) - \frac{1}{2}(X - M_2)^T \Sigma_2^{-1}(X - M_2) + \frac{1}{2}\ln\frac{|\Sigma_1|}{|\Sigma_2|},$$

a Bajesovo pravilo odlučivanja minimalne greške postaje:

$$h(X) \lessgtr \omega 1 \omega 2 \ln\frac{P_1}{P_2}.$$

3.1.1 Bajesovski linearni klasifikator

Kada su kovarijacione matrice obeju klasa jednake, $\Sigma_1 = \Sigma_2 = \Sigma$, granica odlučivanja postaje linearna funkcija po X:

$$h(X) = (M_2 - M_1)^T \Sigma^{-1} X + \frac{1}{2}(M_1^T \Sigma^{-1} M_1 - M_2^T \Sigma^{-1} M_2) \lessgtr_{\omega_2}^{\omega_1} 2\ln\frac{P_1}{P_2}.$$

Ovakav klasifikator se naziva Bajesovskim linearnim klasifikatorom. Za njegovu primenu dovoljno je poznavati vektore matematičkog očekivanja i kovarijacione matrice klasa, a funkcije gustine verovatnoće ne moraju biti poznate u analitičkom obliku. Pored toga, linearni klasifikator se često primenjuje i kada raspodele nisu normalne, jer ga odlikuje mala osetljivost na promene u statističkim karakteristikama podataka.

Opšta forma linearnog klasifikatora je:

$$h(X) = V^T X + v_0 \lessgtr_{\omega_2}^{\omega_1} 0,$$

gde se vektor V i skalar v_0 biraju optimizacijom pogodno izabrane kriterijumske funkcije.

Jedan od najčešće korišćenih kriterijuma je Fišerov kriterijum:

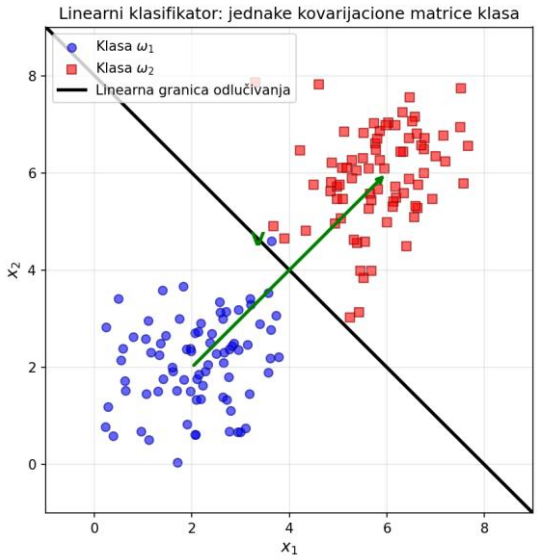
$$f = \frac{(\eta_1 - \eta_2)^2}{\sigma_1^2 + \sigma_2^2},$$

koji favorizuje veliko rastojanje između projekcija srednjih vrednosti klasa, a penalizuje velike unutarklasne varijanse. Za ovaj kriterijum optimalni vektor V ima oblik:

$$V = \left[\frac{1}{2}\Sigma_1 + \frac{1}{2}\Sigma_2\right]^{-1} (M_2 - M_1).$$

Geometrijska interpretacija Fišerovog kriterijuma je intuitivna: traži se pravac projekcije u kome su klase što više razdvojene u odnosu na njihovo unutarklasno rasipanje. Kada su kovarijacione matrice jednake, ovaj pravac je proporcionalan razlici vektora sredina, što odgovara intuiciji. Vrednost praga v_0 određuje se posebno, najčešće metodom resupstitucije ili hold-out metodom. Linearni klasifikator, uprkos jednostavnosti, u praksi često daje iznenađujuće dobre rezultate čak i kada pretpostavke o normalnosti raspodele nisu ispunjene, zbog čega se često koristi kao polazna tačka pre primene složenijih modela.

Slika 3-1 ilustruje slučaj kada su kovarijacione matrice klasa jednake, tj. granica odlučivanja je linearna, a vektor V predstavlja Fišerov pravac projekcije duž koga su klase najbolje razdvojene.



Slika 3-1 Linearni klasifikator za slučaj jednakih kovarijacionih matrica klasa. Zelena strelica predstavlja Fišerov pravac projekcije V, a crna linija linearnu granicu odlučivanja normalnu na taj pravac.

Zanimljivo je da u kontekstu neuravnoteženih klasa, kakav je slučaj u ovom radu, ni optimalan V ni optimalan v_0 ne garantuju dobar rezultat na manjinskoj klasi, jer kriterijum minimizuje ukupan broj grešaka, a većinska klasa dominira tim brojem. Ovo je suštinski razlog zašto linearni klasifikator sa ponderisanjem klasa ili eksplicitnim podešavanjem praga daje bolje rezultate od "standardnog" linearnog klasifikatora na ovakvim problemima.

3.1.2 Kvadratni klasifikator

Kada klase nisu linearno separabilne ili kada su kovarijacione matrice klasa međusobno različite, linearni klasifikator nije dovoljan. U tom slučaju se koristi kvadratni klasifikator opšte forme:

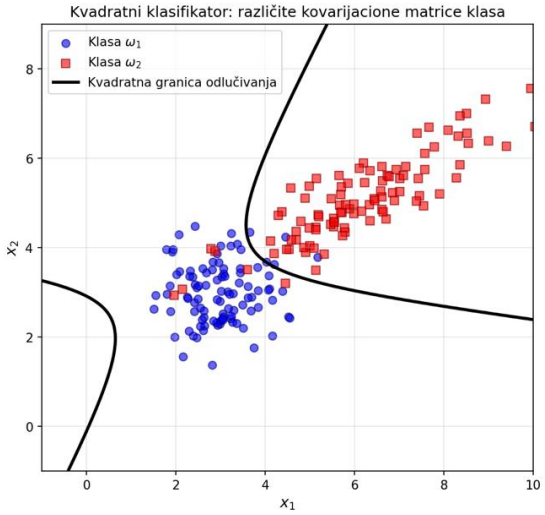
$$h(X) = X^T Q X + V^T X + v_0 \lessgtr_{\omega_2}^{\omega_1} 0$$

Ovo je prirodan izbor jer je Bajesovski klasifikator za normalne raspodele sa nejednakim kovarijacionim matricama upravo kvadratnog tipa. Granica odlučivanja može biti parabola, elipsa, hiperbola ili prava, zavisno od statistika raspodela klasa.

Kvadratni klasifikator nudi veću fleksibilnost od linearnog, ali za cenu većeg broja parametara koje treba odrediti iz obučavajućeg skupa. Zbog toga je za pouzdanu procenu parametara potreban veći broj uzoraka.

Kvadratni klasifikator može se projektovati i metodom željenog izlaza, koja ne zahteva eksplicitno poznavanje kovarijacionih matrica trećeg i četvrtog reda. U toj formulaciji, kvadratna diskriminaciona funkcija se prividno linearizuje uvođenjem proširenog vektora obeležja koji sadrži i proizvode originalnih koordinata, a optimalni parametri određuju se minimizacijom srednje kvadratne greške u odnosu na željene izlaze na obučavajućem skupu. Ovo je numerički pogodniji pristup za višedimenzionalne probleme.

Slika 3-2 prikazuje primer kada su kovarijacione matrice klasa različite- granica odlučivanja postaje kvadratna kriva koja prati oblik raspodela.



Slika 3-2 Kvadratni klasifikator za slučaj različitih kovarijacionih matrica klasa.

U ovom radu kvadratni klasifikator nije direktno primenjen, ali njegova uloga se indirektno pojavljuje kroz RBF SVM. Kernel trik koji RBF SVM koristi implicitno projektuje podatke u prostor veće dimenzionalnosti u kome linearni klasifikator u tom prostoru odgovara nelinearnom klasifikatoru u originalnom prostoru, što je konceptualno blisko kvadratnom ili višem stepenu granice odluke. Razlika je u tome što SVM tu granicu bira optimizacijom margine, dok klasični kvadratni klasifikator to radi minimizacijom greške na obučavajućem skupu.

3.2 Neparametarske metode klasifikacije

Neparametarske metode ne pretpostavljaju oblik raspodele podataka. Umesto toga, funkcija gustine verovatnoće se procenjuje direktno iz raspoloživih uzoraka, a klasifikator se projektuje na osnovu te procene. Ovakav pristup je primenljiv i onda kada raspodele klasa nisu normalne ili njihov analitički oblik nije poznat.

Osnovna ideja neparametarske estimacije funkcije gustine verovatnoće potiče od sledeće opservacije. Neka je na raspolaganju N odbiraka slučajne promenljive i neka je $L(X)$ oblast oko tačke X zapremine v. Ako je v dovoljno malo, funkciju gustine verovatnoće u toj oblasti možemo smatrati konstantnom, i tada važi:

$$\hat{f}(X) = \frac{k(X)}{Nv},$$

gde $k(X)$ predstavlja broj odbiraka koji se nalaze u oblasti $L(X)$. Zavisno od toga da li se fiksira zapremina v ili broj odbiraka k, dobijaju se dve osnovne klase metoda- Parzenova estimacija i metoda k najbližih suseda.

Primena neparametarskih metoda u klasifikaciji je direktna- struktura klasifikatora preuzima se iz teorije odlučivanja opisane u poglavlju 2, dok se procene funkcija gustine dobijaju neparametarski iz uzoraka.

3.2.1 Parzenova estimacija

Parzenova estimacija fiksira zapreminu oblasti v, dok broj odbiraka $k(X)$ unutar te oblasti postaje slučajna promenljiva koja zavisi od položaja tačke X. Najopštiji oblik ove metode zasniva se na kernel funkcijama. Oko svakog od N raspoloživih odbiraka X_i postavlja se jedna kernel funkcija $K(\cdot)$, i procena funkcije gustine verovatnoće dobija oblik:

$$\hat{f}(X) = \frac{1}{N}\sum_{k=1}^{N} K(X - X_k)$$

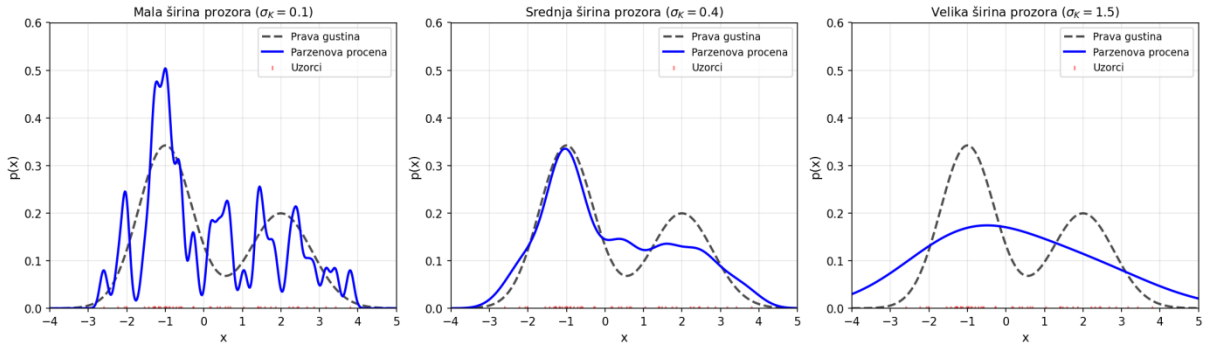
Kernel funkcija mora zadovoljiti uslove koji važe za funkcije gustine verovatnoće:

$$K(x) \geq 0, \int_{-\infty}^{\infty} K(x)dx = 1$$

Najčešće korišćen kernel je normalni (Gausov), čija varijansa $\sigma^2{}_k$ kontroliše širinu prozora. Suviše mala varijansa naglašava sitne detalje kojih u pravoj raspodeli nema, dok

suviše velika varijansa glača funkciju i gubi značajne detalje. Optimalan izbor $\sigma^2{}_k$ zavisi od broja raspoloživih odbiraka N i oblika same raspodele, i po pravilu se određuje minimizacijom srednje kvadratne greške estimacije.

Slika 3-3 ilustruje uticaj širine prozora na kvalitet Parzenove procene gustine.



Slika 3-3 Parzenova estimacija gustine sa različitim širinama Gausovog kernela. Mala širina (levo) daje izrazito neravnu procenu koja prati pojedinačne uzorke, srednja širina (sredina) najbolje aproksimira pravu gustinu, dok velika širina (desno) preglađuje procenu i gubi bitne karakteristike raspodele.

Parzenova estimacija predstavlja teorijsku osnovu na kojoj se zasniva metoda k najbližih suseda, koja je direktno korišćena u ovom radu.

Veza između Parzenove estimacije i *KNN* metode je direktna i intuitivna. Dok Parzenova estimacija fiksira zapreminu oblasti i pita „koliko odbiraka pada unutar?", *KNN* fiksira broj odbiraka i pita „kolika oblast je potrebna da ih obuhvati?".

3.2.2 Metoda k najbližih suseda (KNN)

Za razliku od Parzenove estimacije, metoda k najbližih suseda fiksira broj odbiraka k, dok zapremina oblasti $v(X)$ postaje slučajna promenljiva- oblast se širi sve dok ne obuhvati tačno k odbiraka. Procena funkcije gustine verovatnoće u tački X tada ima oblik:

$$\hat{f}(X) = \frac{k-1}{Nv(X)}.$$

Može se pokazati da je ova procena nepomerena i konzistentna ukoliko parametar k zadovoljava uslove:

$$\lim_{N\to\infty} k = \infty, \qquad \lim_{N\to\infty} \frac{k}{N} = 0.$$

Klasifikacija metodom *KNN* direktna je primena ove estimacije. Za dati merni vektor X, klasifikator se zasniva na poređenju procenjenih funkcija gustine verovatnoće dveju klasa:

$$-\ln\frac{\hat{f}_1(X)}{\hat{f}_2(X)} = -\ln\frac{\frac{k_1-1}{N_1 v_1(X)}}{\frac{k_2-1}{N_2 v_2(X)}} \lessgtr_{\omega_2}^{\omega_1} t,$$

gde su N_1 i N_2 broj odbiraka iz prve i druge klase, a $v_1(X)$ i $v_2(X)$ zapremine oblasti koje obuhvataju k_1 i k_2 najbližih suseda iz svake klase. Klasifikacija se vrši glasanjem- merni vektor X se pripisuje klasi koja je najzastupljenija među k najbližih suseda u zajedničkom trening skupu:

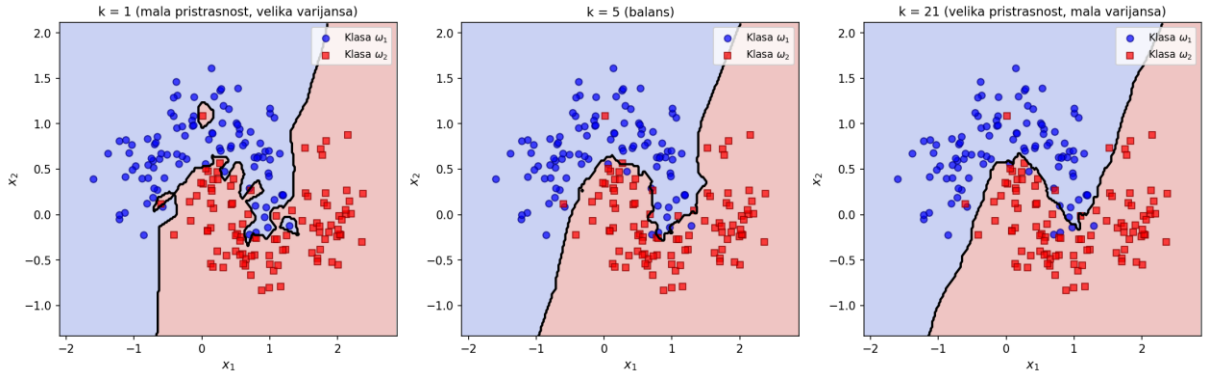
$$\hat{y} = \arg\max_c \sum_{i\in\mathcal{N}_K(X)} \mathbf{1}[y_i = c].$$

Udaljenost između vektora računa se najčešće po Euklidskoj normi:

$$d(X, X') = \sqrt{\sum_{j=1}^{n}(X_j - X'_j)^2}.$$

Uticaj parametra k direktno određuje kompromis između pristranosti i varijanse klasifikatora. Mali k daje fleksibilnu granicu odlučivanja koja prati lokalnu strukturu podataka, ali je osetljiva na šum, u oblastima visoke gustine verovatnoće pojavljuju se veliki pikovi procene vezani za položaje konkretnih odbiraka. Povećanjem k granica se gladi i procena postaje stabilnija, ali u oblastima niske gustine $v(X)$ postaje prevelika i narušava pretpostavku o lokalnoj konstantnosti funkcije gustine. Optimalna vrednost k određuje se unakrsnom validacijom i zavisi od broja raspoloživih odbiraka N.

Slika 3-4 grafički prikazuje kako se granica odlučivanja menja u zavisnosti od *k*.



Slika 3-4 Granica odlučivanja KNN klasifikatora za različite vrednosti parametra k. Sa k = 1 granica je zupčasta i osetljiva na pojedinačne primere (velika varijansa), sa k = 5 dobija se balansirana granica koja prati strukturu podataka, dok sa k = 21 granica postaje previše glatka i propušta lokalne karakteristike (velika pristrasnost).

Osnovno ograničenje metode je prokletstvo dimenzionalnosti- u visokim dimenzijama Euklidska udaljenost gubi diskriminativnu moć jer razlike između najbližeg i najudaljenijeg suseda postaju zanemarljive. Zbog toga je normalizacija obeležja pre primene *KNN* neophodan korak.

Pored prokletstva dimenzionalnosti, *KNN* ima i praktično ograničenje vezano za neuravnotežene skupove podataka. Kada je jedna klasa znatno zastupljenija od druge, glasanje *k* suseda prirodno favorizuje većinsku klasu jer su u proseku susedi svakog primera uglavnom iz te klase. U ovom radu to je ublaženo tehnikama ponderisanja po rastojanju- bliži susedi imaju veći uticaj na odluku i stratifikovanim uzorkovanjem trening skupa.

Posebno je važno napomenuti da su rezultati *KNN* metode osetljivi na izbor konkretnog trening skupa kada je on podskup većeg skupa podataka. Budući da *KNN* klasifikuje svaki novi primer na osnovu njegovih lokalnih suseda u trening skupu, različiti slučajni podskupovi mogu dati različitu lokalnu strukturu oko pojedinih primera i time različite rezultate. Ova osetljivost će biti detaljnije razmotrena u analizi rezultata u poglavlju 6.5.

Metode opisane u ovom poglavlju zajedno sa SVM metodom opisanom u narednom poglavlju čine skup klasifikatora primenjenih na problem detekcije lažnih transakcija. Za razliku od parametarskih metoda koje procenjuju gustinu verovatnoće klasa i neparametarskih metoda koje je aproksimiraju iz podataka, SVM direktno konstruiše granicu odluke optimizacijom geometrijske margine, bez ikakvog modelovanja raspodele podataka.

4 Support Vector Machines (SVM)

Jedna od centralnih metoda klasifikacije razmatranih u ovom radu je metoda potpornih vektora (*Support Vector Machines*, SVM), koja predstavlja jedan od najčešće korišćenih algoritama nadziranog mašinskog učenja. SVM je prvobitno razvio Vladimir Vapnik 1963. godine, a značajniji napredak ostvaren je tokom devedesetih uvođenjem mekog ograničenja margine i kernel trika, o kojima će biti reči u nastavku.

Osnovna ideja SVM-a je da pronađe granicu odluke koja ne samo da ispravno klasifikuje podatke za obučavanje, već je i što udaljenija od primera obe klase. Za razliku od, na primer perceptrona koji pronalazi bilo koju granicu koja razdvaja podatke, SVM uvek traži onu sa maksimalnom marginom. Intuitivno, veća margina znači da je klasifikator stabilniji na male promene u podacima i bolje generalizuje na nove primere. Pored toga, SVM se može primeniti i na podatke koji nisu linearno separabilni, što ga čini pogodnim za širok spektar praktičnih problema.

4.1 Matematičke osnove

4.1.1 Vektori i skalarni proizvod

Svaki primer iz skupa podataka predstavljen je kao vektor u n-dimenzionalnom realnom prostoru $\mathbb{R}^n$. Vektor $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ karakterišu dve veličine: intenzitet (norma) i smer.
Euklidska norma vektora **x** definisana je kao:

$$\| \mathbf{x} \| = \sqrt{\sum_{i=1}^{n} x_i^2}\,.$$

Jedinični vektor (vektor smera) dobija se normalizacijom:

$$\hat{\mathbf{u}} = \frac{\mathbf{x}}{\| \mathbf{x} \|},$$

pri čemu je $\| \hat{\mathbf{u}} \| = 1$ po definiciji.

Skalarni proizvod dva vektora $\mathbf{x}, \mathbf{z} \in \mathbb{R}^n$ definiše se algebarski kao:

$$\mathbf{x} \cdot \mathbf{z} = \sum_{i=1}^{n} x_i\, z_i,$$

što je ekvivalentno geometrijskoj definiciji:

$$\mathbf{x} \cdot \mathbf{z} = \| \mathbf{x} \| \cdot \| \mathbf{z} \| \cdot \cos\theta,$$

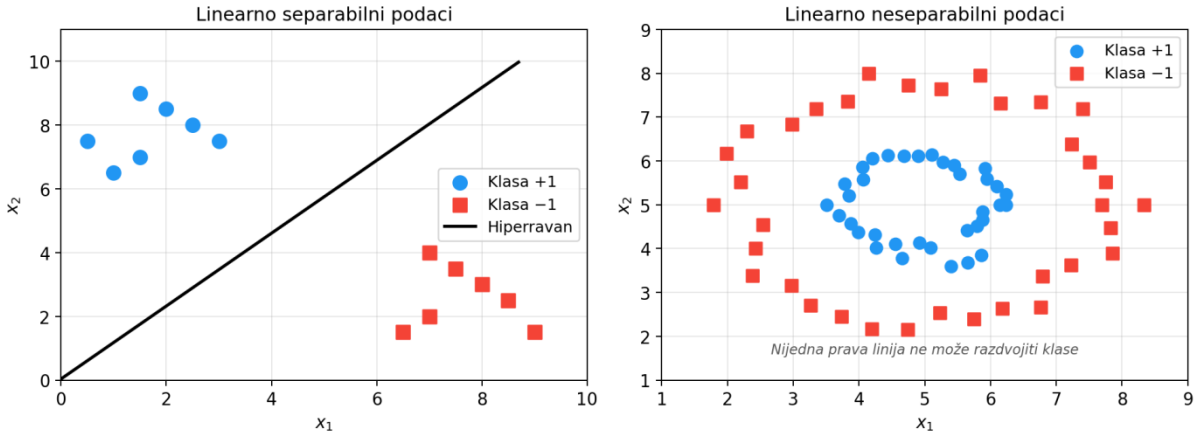
gde je θ ugao između vektora. Predznak skalarnog proizvoda direktno odražava međusobnu orijentaciju vektora: pozitivan je kada je ugao manji od 90°, nula kada su vektori ortogonalni,

a negativan kada je ugao veći od 90°. Ova osobina ima ključnu ulogu u geometrijskoj interpretaciji granice odluke SVM modela.

4.1.2 Hiperravan i linearna separabilnost

Skup podataka $\{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^{m}$, gde su $\mathbf{x}^{(i)} \in \mathbb{R}^n$ulazni vektori, a $y^{(i)} \in \{-1, +1\}$oznake klasa, naziva se linearno separabilnim ukoliko postoji hiperravan koja ga deli na dve klase bez grešaka. Na slici *4-1* su prikazani primeri linearno separabilnih (levo) i linearno neseparabilnih podataka (desno).

Figura 1: Linearna separabilnost podataka



Slika 4-1 Linearno separabilni podaci (levo), gde postoji prava linija koja razdvaja dve klase i liinearno neseparabilni podaci (desno), kod kojih takva linija ne postoji

Hiperravan u prostoru $\mathbb{R}^n$ je afini potprostor dimenzije $n - 1$, definisan jednačinom:

$$\mathbf{w} \cdot \mathbf{x} + b = 0,$$

gde je $\mathbf{w} \in \mathbb{R}^n$normalni vektor hiperravni, a $b \in \mathbb{R}$ pomeraj (bias). Hiperravan deli prostor na dva poluotvora:

$$\mathbf{w} \cdot \mathbf{x} + b > 0 \quad \text{i} \quad \mathbf{w} \cdot \mathbf{x} + b < 0.$$

Na osnovu toga, funkcija hipoteze za binarnu klasifikaciju definiše se kao:

$$h(\mathbf{x}) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b).$$

Bitno je napomenuti da je orijentacija hiperravni određena vektorom w, dok parametar b određuje njen položaj u prostoru. Skup svih hiperravni koje razdvajaju podatke parametrizovan je parom (w, b).

4.2 Optimalna hiperravan i margina

4.2.1 Problem poređenja hiperravni

Perceptron, kao jedan od najjednostavnijih linearnih klasifikatora, garantuje pronalaženje neke hiperravni koja separira linearno separabilne podatke, ali ne i iste hiperravni pri svakom pokretanju. Pošto su težine nasumično inicijalizovane, a pogrešno klasifikovani primeri nasumično birani, algoritam svaki put konvergira ka drugačijem rešenju. Na skupu za obučavanje sve pronađene hiperravni mogu imati grešku nula, ali na novim podacima neke od njih generalizuju znatno lošije od ostalih.

Ovo direktno motiviše centralnu ideju SVM-a: ne tražiti bilo koju separišuću hiperravan, već *optimalnu* koja će se najrobusnije ponašati na neviđenim podacima. Da bismo definisali šta znači optimalna, potreban nam je numerički kriterijum koji omogućava poređenje dve hiperravni.

4.2.2 Funkcionalna margina

Za primer $\left(\mathbf{x}^{(i)}, y^{(i)}\right)$i hiperravan definisanu parametrima $(\mathbf{w}, b)$, vrednost $\mathbf{w} \cdot \mathbf{x}^{(i)} + b$ govori nam koliko je primer udaljen od hiperravni i na kojoj se strani nalazi. Uvođenjem oznake klase $y^{(i)} \in \{-1, +1\}$ definišemo funkcionalnu marginu primera:

$$\hat{\gamma}^{(i)} = y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right).$$

Predznak funkcionalne margine direktno odražava ispravnost klasifikacije: $\hat{\gamma}^{(i)} > 0$ ukoliko je primer ispravno klasifikovan, a $\hat{\gamma}^{(i)} < 0$u suprotnom. Funkcionalna margina skupa podataka definiše se kao minimum po svim primerima:

$$\hat{\gamma} = \min_i \; y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right).$$

Međutim, funkcionalna margina ima suštinski nedostatak- nije invarijantna na skaliranje. Množenjem vektora $\mathbf{w}$ i skalara b istom konstantom $c > 0$ dobija se ista hiperravan, ali funkcionalna margina raste proporcionalno sa c. To znači da za bilo koju hiperravan uvek možemo pronaći drugu sa proizvoljno većom funkcionalnom marginom, što ovaj kriterijum čini beskorisnim za poređenje.

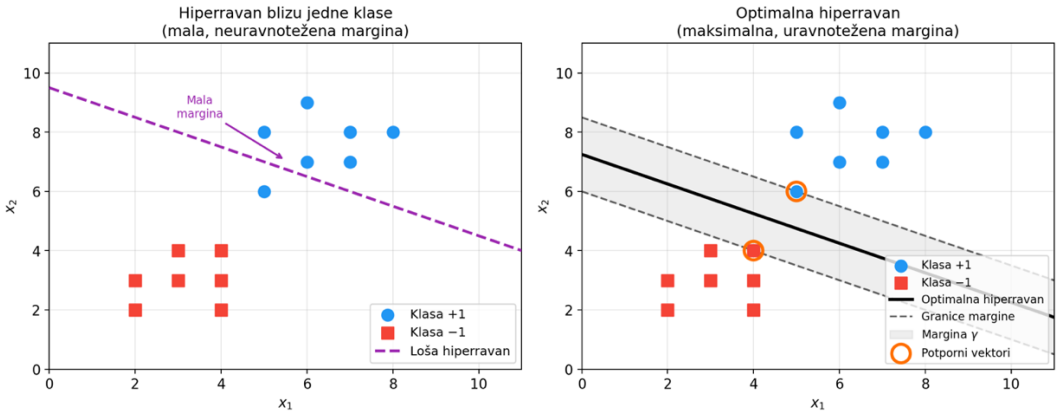
4.2.3 Geometrijska margina

Da bismo otklonili problem invarijantnosti na skaliranje, uvodimo geometrijsku marginu, koja meri stvarno Euklidsko rastojanje između primera i hiperravni. Geometrijska margina primera $\left(\mathbf{x}^{(i)}, y^{(i)}\right)$ definisana je kao:

$$\gamma^{(i)} = y^{(i)}\left(\frac{\mathbf{w}}{\| \mathbf{w} \|} \cdot \mathbf{x}^{(i)} + \frac{b}{\| \mathbf{w} \|}\right).$$

Na slici *4-2* prikazano je poređenje loše i optimalne hiperravni koja maksimizuje marginu.

Figura 2: Poređenje hiperravni — loša vs. optimalna



Slika 4-2 Poređenje loše hiperravni (levo), koja je bliska jednoj klasi i ima usku marginu, i optimalne hiperravni (desno), koja maksimizuje rastojanje od podataka obe klase

Geometrijska margina skupa podataka je:

$$\gamma = \min_i \; y^{(i)} \left(\frac{\mathbf{w}}{\| \mathbf{w} \|} \cdot \mathbf{x}^{(i)} + \frac{b}{\| \mathbf{w} \|} \right).$$

Između funkcionalne i geometrijske margine postoji direktna veza:

$$\gamma = \frac{\hat{\gamma}}{\| \mathbf{w} \|}.$$

Geometrijska margina je invarijantna na skaliranje- množenje $\mathbf{w}$ i b konstantom c ne menja njenu vrednost. Ona predstavlja pravo geometrijsko rastojanje između podataka i granice odluke, što je čini smislenim kritrijumom za poređenje hiperravni.

4.2.4 Optimalna hiperravan

Optimalna hiperravan definiše se kao ona koja maksimizuje geometrijsku marginu skupa podataka. Intuitivno, što je hiperravan dalje od podataka obe klase, model je stabilniji i manja je verovatnoća da će mali šum u podacima promeniti klasifikaciju.

Pronalaženje optimalne hiperravni svodi se na sledeći optimizacioni problem:

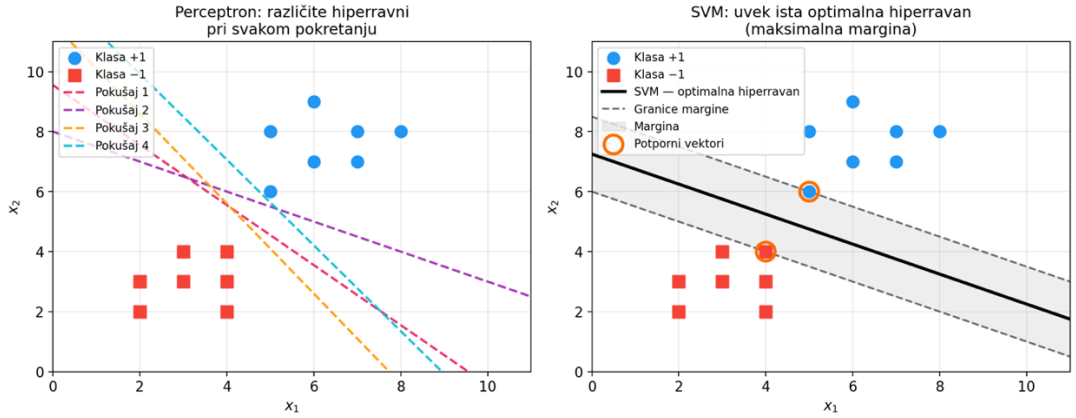
$$\max_{\mathbf{w},b} \; \gamma \qquad \text{uz uslov} \qquad y^{(i)} \left(\frac{\mathbf{w}}{\| \mathbf{w} \|} \cdot \mathbf{x}^{(i)} + \frac{b}{\| \mathbf{w} \|} \right) \geq \gamma, \forall i.$$

Pošto je $\gamma = \hat{\gamma} / \| \mathbf{w} \|$, maksimizacija geometrijske margine ekvivalentna je maksimizaciji $\hat{\gamma} / \| \mathbf{w} \|$. Skalom invarijantnosti možemo bez gubitka opštosti postaviti $\hat{\gamma} = 1$, što problem svodi na minimizaciju $\| \mathbf{w} \|$, odnosno $\| \mathbf{w} \|^2$ (radi matematičke pogodnosti).

Time dolazimo do standardne formulacije SVM optimizacionog problema, koja će biti detaljno razrađena u narednoj sekciji.

Na slici *4-3* ilustrovano je kako perceptron pronalazi različite hiperravni pri svakom pokretanju, dok SVM uvek pronalazi istu optimalnu hiperravan.

Figura 3: Perceptron vs. SVM



Slika 4-3 Perceptron pronalazi različite hiperravni pri svakom pokretanju algoritma (levo), dok SVM uvek pronalazi istu optimalnu hiperravan sa maksimalnom marginom (desno)

4.3 Formulacija optimizacionog problema

4.3.1 Primarni optimizacioni problem

Kao što je pokazano u prethodnoj sekciji, pronalaženje optimalne hiperravni ekvivalentno je maksimizaciji geometrijske margine γ. Koristeći vezu između funkcionalne i geometrijske margine $\gamma = \hat{\gamma}/\| \mathbf{w} \|$, i postavljanjem $\hat{\gamma} = 1$ bez gubitka opštosti, maksimizacija margine svodi se na minimizaciju norme vektora $\mathbf{w}$. Kvadriranje norme i uvođenje faktora $\frac{1}{2}$ vrše se isključivo radi matematičke pogodnosti pri diferencirovanju, bez uticaja na rešenje. Time dolazimo do standardnog oblika primarnog optimizacionog problema:

$$\min_{\mathbf{w},b} \ \frac{1}{2} \| \mathbf{w} \|^2,$$

$$\text{uz uslove: } \ y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right) \geq 1, \forall i = 1, \dots, m.$$

Ovo je konveksni kvadratni optimizacioni problem (*Quadratic Programming*, QP) sa linearnim ograničenjima. Konveksnost garantuje postojanje jedinstvenog globalnog minimuma, što je posebno povoljna osobina sa numeričkog stanovišta.

Uslov $y^{(i)}(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) \geq 1$ zahteva da svaki primer bude ispravno klasifikovan i da se nalazi na ispravnoj strani granice margine. Primeri koji se nalaze tačno na granici margine, tj. za koje važi $y^{(i)}(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) = 1$, nazivaju se support vectors i igraju centralnu ulogu u definisanju optimalne hiperravni.

4.3.2 Lagranževi multiplikatori i Lagranževa funkcija

Za rešavanje optimizacionog problema sa ograničenjima koristi se metoda Lagranževih multiplikatora. Uvođenjem jednog nenegativnog multiplikatora $\alpha_i \geq 0$ za svako ograničenje, konstruiše se Lagranževa funkcija:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \| \mathbf{w} \|^2 - \sum_{i=1}^{m} \alpha_i \left[y^{(i)} \left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b \right) - 1 \right].$$

Primarni problem tada postaje traženje sedlaste tačke Lagranževe funkcije:

$$\min_{\mathbf{w}, b} \max_{\boldsymbol{\alpha} \geq 0} \mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}).$$

4.3.3 Wolfe-ov dualni problem

Direktno rešavanje primarnog problema je nepraktično za veće skupove podataka. Zahvaljujući teoriji dualnosti i uz ispunjenost Slater-ovog uslova koji važi za afina ograničenja, može se pokazati da važi jaka dualnost- minimum primarnog problema jednak je maksimumu dualnog problema.

Dualni problem dobija se uzimanjem parcijalnih izvoda Lagranževe funkcije po $\mathbf{w}$ i b i izjednačavanjem sa nulom:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0 \implies \mathbf{w} = \sum_{i=1}^{m} \alpha_i \, y^{(i)} \mathbf{x}^{(i)}$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \implies \sum_{i=1}^{m} \alpha_i \, y^{(i)} = 0$$

Zamenom ovih relacija u Lagranževu funkciju eliminiše se zavisnost od $\mathbf{w}$ i b, i dobija se **Wolfe-ov dualni problem**:

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \, \alpha_j y^{(i)} y^{(j)} \left(\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)} \right),$$

$$\text{uz uslove: } \alpha_i \geq 0, \forall i; \sum_{i=1}^{m} \alpha_i \, y^{(i)} = 0$$

Ključna prednost dualnog problema je što funkcija cilja zavisi isključivo od skalarnih proizvoda između parova primera $\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}$, a ne od dimenzionalnosti prostora n. Ova osobina direktno omogućava primenu kernel trika opisanog u sekciji 4.5.

4.3.4 KKT uslovi i potporni vektori

Budući da se radi o konveksnom problemu sa nejednakosnim ograničenjima, neophodni i dovoljni uslovi optimalnosti su Karush-Kuhn-Tucker (KKT) uslovi:

$$\mathbf{w} - \sum_{i=1}^{m} \alpha_i \, y^{(i)} \mathbf{x}^{(i)} = 0;$$
$$\sum_{i=1}^{m} \alpha_i \, y^{(i)} = 0;$$
$$\alpha_i \geq 0, \forall i;$$
$$y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right) - 1 \geq 0, \forall i;$$
$$\alpha_i\left[y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right) - 1\right] = 0, \forall i.$$

Poslednji uslov naziva se uslov komplementarne labavosti i ima ključnu implikaciju: za svaki primer i nvaži ili $\alpha_i = 0$ ili $y^{(i)}(\mathbf{w} \cdot \mathbf{x}^{(i)} + b) = 1$. To znači da jedino primeri koji leže tačno na granici margine mogu imati $\alpha_i > 0$ i upravo to su support vektori. Svi ostali primeri imaju $\alpha_i = 0$ i ne doprinose definisanju hiperravni.

Nakon rešavanja dualnog problema i dobijanja vektora multiplikatora $\boldsymbol{\alpha}$, parametri hiperravni rekonstruišu se kao:

$$\mathbf{w} = \sum_{i \in \mathcal{SV}} \alpha_i \, y^{(i)} \mathbf{x}^{(i)}$$
$$b = \frac{1}{| \, \mathcal{SV} \, |} \sum_{i \in \mathcal{SV}} \left(y^{(i)} - \mathbf{w} \cdot \mathbf{x}^{(i)}\right)$$

gde $\mathcal{SV}$ označava skup support vektora. Konačna funkcija hipoteze glasi:

$$h(\mathbf{x}) = \text{sign}\left(\sum_{i \in \mathcal{SV}} \alpha_i \, y^{(i)}\left(\mathbf{x}^{(i)} \cdot \mathbf{x}\right) + b\right).$$

Suma u funkciji hipoteze teče samo po support vektorima, kojih je tipično mali broj u odnosu na ukupan skup podataka. Upravo zbog toga se SVM naziva i **retkom kernel mašinom** (*sparse kernel machine*).

4.4 Meka margina

4.4.1 Ograničenja tvrde margine

Optimizacioni problem formulisan u prethodnoj sekciji pretpostavlja da su podaci linearno separabilni, tj. da postoji hiperravan koja savršeno razdvaja dve klase bez ikakve greške. Ovakav model naziva se SVM sa **tvrdom marginom** (*hard margin SVM*). U praksi, međutim, realni podaci gotovo nikada nisu savršeno linearno separabilni. Dva tipična scenarija koja narušavaju linearnu separabilnost su:

- **Outlier koji smanjuje marginu**: Jedan atipičan primer može se naći znatno bliže hiperravni nego ostali primeri svoje klase, što drastično sužava marginu i rezultuje modelom koji loše generalizuje na novim podacima.
- **Outlier koji narušava linearnu separabilnost**: Jedan jedini atipičan primer može učiniti podatke potpuno linearno neseparabilnim, čime hard margin SVM postaje beskoristan jer ne postoji rešenje koje zadovoljava sva ograničenja.

Oba scenarija ukazuju na potrebu za fleksibilnijim modelom koji dozvoljava određeni stepen grešaka pri klasifikaciji.

4.4.2 Slack promenljive

Vapnik i Cortes su 1995. godine uveli modifikaciju originalnog SVM-a koja dozvoljava klasifikatoru da napravi određene greške. Ideja se zasniva na uvođenju **slack promenljivih** $\xi_i \geq 0$, po jedna za svaki primer, kojima se relaksira originalno ograničenje tvrde margine:

$$y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right) \geq 1 - \xi_i, \xi_i \geq 0, \forall i.$$

Slack promenljiva $\xi_i$meri za koliko primer i krši originalno ograničenje tvrde margine:

- $\xi_i = 0$: primer je ispravno klasifikovan i nalazi se van margine
- $0 < \xi_i \leq 1$: primer je unutar margine, ali još uvek ispravno klasifikovan
- $\xi_i > 1$: primer je pogrešno klasifikovan

Da bismo sprečili trivijalno rešenje u kome su sve slack promenljive beskonačno velike, njihov zbir dodaje se u funkciju cilja kao kazna. Uvođenjem hiperparametra $C > 0$ koji kontroliše težinu ove kazne, dobijamo **optimizacioni problem meke margine**:

$$\min_{\mathbf{w},b,\xi} \ \frac{1}{2} \| \mathbf{w} \|^2 + C \sum_{i=1}^{m} \xi_i,$$

uz uslove: $y^{(i)}\left(\mathbf{w} \cdot \mathbf{x}^{(i)} + b\right) \geq 1 - \xi_i, \xi_i \geq 0, \forall i.$

Dodavanje sume slack promenljivih u funkciju cilja naziva se **regularizacija**. Rezultujuće rešenje predstavlja hiperravan koja istovremeno maksimizuje marginu i minimizuje ukupnu grešku klasifikacije, uz kompromis koji kontroliše parametar C.

Primenom iste procedure Lagranževih multiplikatora kao u sekciji 4.3, dobija se Wolfe-ov dualni problem meke margine, identičan dualnom problemu tvrde margine uz jednu izmenu u ograničenju:

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \, \alpha_j y^{(i)} y^{(j)} \left(\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}\right),$$

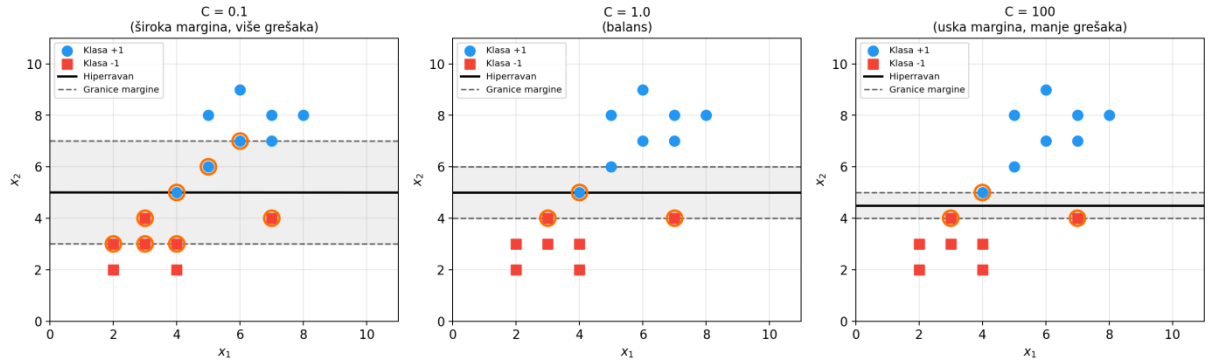
$$\text{uz uslove: } \; 0 \leq \alpha_i \leq C, \forall i; \sum_{i=1}^{m} \alpha_i \, y^{(i)} = 0.$$

Ograničenje $0 \leq \alpha_i \leq C$ naziva se **box constraint** i jedina je razlika u odnosu na tvrdu marginu, gde je $\alpha_i \geq 0$ bez gornje granice.

4.4.3 Uloga hiperparametra C

Parametar C rešava kompromis između širine margine i tolerancije na greške klasifikacije. Veliko C znači da algoritam strogo kažnjava greške, što rezultuje užom marginom ali manjim brojem pogrešno klasifikovanih primera na skupu za obučavanje, a u graničnom slučaju $C \to \infty$, soft margin SVM degeniše u hard margin SVM. Malo C znači da algoritam toleriše više grešaka u zamenu za širu marginu, što može poboljšati generalizaciju na šumovitim podacima. Slika 4-4 prikazuje efekat različitih vrednosti parametra C na marginu i granicu odluke.

Figura 4: Efekat parametra C na marginu i granicu odluke



Slika 4-4 Efekat parametra C na marginu i granicu odluke.

Ne postoji univerzalna vrednost C koja odgovara svim problemima. Standardni pristup izboru optimalnog C je pretraga po mreži u kombinaciji sa unakrsnom validacijom (cross-validation).

4.5 Kernel trik

4.5.1 Motivacija

Formulacije iz prethodnih sekcija pretpostavljaju linearnu granicu odluke. Međutim, mnogi realni problemi zahtevaju nelinearnu granicu odluke. Osnovna ideja za prevazilaženje ovog ograničenja je transformacija ulaznih podataka u prostor veće dimenzionalnosti u kome postaju linearno separabilni, primenom funkcije:

$$\phi: \mathbb{R}^n \to \mathbb{R}^N, \qquad N > n.$$

SVM se tada primenjuje na transformisane podatke $\phi(\mathbf{x}^{(i)})$ umesto na originalne $\mathbf{x}^{(i)}$. Međutim, eksplicitna transformacija svakog primera može biti računski izuzetno zahtevna, posebno kada je N veliko ili čak beskonačno dimenzionalno. Ključna opservacija je da dualni problem i funkcija hipoteze ne zavise od samih vektora, već isključivo od njihovih međusobnih skalarnih proizvoda $\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}$. Ovo omogućava primenu kernel trika.

4.5.2 Kernelska funkcija i kernel trik

Kernelska funkcija definiše se kao funkcija koja vraća skalarni proizvod u transformisanom prostoru bez eksplicitnog izračunavanja same transformacije:

$$K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}) = \phi(\mathbf{x}^{(i)}) \cdot \phi(\mathbf{x}^{(j)}).$$

Kernel trik se sastoji u zameni skalarnog proizvoda $\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}$ kernelskom funkcijom $K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$ u dualnom problemu. Time se dobija kernelizovani dualni problem:

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y^{(i)} y^{(j)} K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}),$$

$$\text{uz uslove: } \; 0 \le \alpha_i \le C, \forall i; \sum_{i=1}^{m} \alpha_i y^{(i)} = 0.$$

Analogno, funkcija hipoteze postaje:

$$h(\mathbf{x}) = \text{sign}\left(\sum_{i \in \mathcal{SV}} \alpha_i y^{(i)} K(\mathbf{x}^{(i)}, \mathbf{x}) + b \right).$$

Na ovaj način moguće je primeniti SVM i na probleme koji nisu linearno separabilni u originalnom prostoru. Umesto eksplicitne transformacije podataka u visokodimenzionalni prostor, dovoljno je definisati kernelsku funkciju koja efikasno izračunava skalarni proizvod u tom prostoru.

4.5.3 Tipovi kernelskih funkcija

U praksi se najčešće koriste sledeći tipovi kernelskih funkcija.

Linearni kernel je najjednostavniji kernel, pogodan je za probleme koji su linearno separabilni u originalnom prostoru (npr. klasifikacija teksta) i odgovara standardnom skalarnom proizvodu:

$$K\left(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}\right) = \mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)}.$$

Polinomijalni kernel stepena $d$definiše se kao:

$$K\left(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}\right) = \left(\mathbf{x}^{(i)} \cdot \mathbf{x}^{(j)} + c\right)^{d},$$

gde je $c \geq 0$ slobodan parametar koji kontroliše uticaj članova nižeg stepena. Povećanjem stepena d granica odluke postaje složenija, ali prevelike vrednosti $d$mogu dovesti do preobučavanja (overfitting) modela.

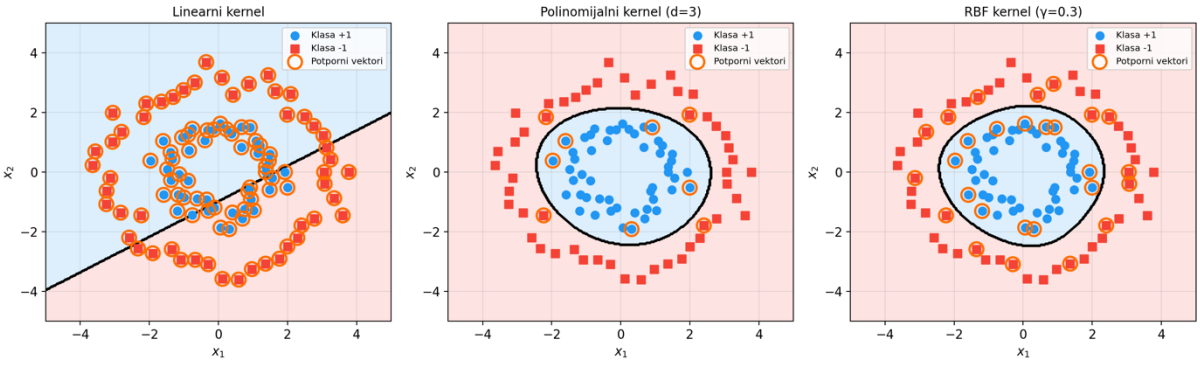
RBF kernel (*Radial Basis Function*), poznat i kao Gausov kernel, definiše se kao:

$$K\left(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}\right) = \exp\left(\quad -\gamma \parallel \mathbf{x}^{(i)} - \mathbf{x}^{(j)} \parallel^2\right), \gamma > 0.$$

RBF kernel projektuje podatke u beskonačnodimenzionalni prostor i u praksi daje dobre rezultate na širokom spektru problema. Parametar γ kontroliše širinu Gausove funkcije: malo γ čini model sličnim linearnom SVM-u, dok veliko γ dovodi do preprilagođavanja jer model postaje previše osetljiv na svaki pojedinačni primer. Standardni pristup izboru optimalnih vrednosti C i γ je pretraga po mreži sa unakrsnom validacijom.

Na slici *4-5* prikazano je poređenje linearnog, polinomijalnog i RBF kernela na istom skupu neseparabilnih podataka.

Figura 5: Poređenje linearnog, polinomijalnog i RBF kernela



Slika 4-5 Poređenje tri kernelske funkcije na linearno neseparabilnom skupu podataka. Linearni kernel (levo) ne uspeva da razdvoji klase, polinomijalni kernel stepena 3 (sredina) daje bolju granicu odluke, a RBF kernel (desno) ispravno klasifikuje podatke.

Zahvaljujući kernel triku, SVM može efikasno raditi u veoma visokodimenzionalnim prostorima, dok složenost algoritma zavisi prvenstveno od broja primera u skupu za obučavanje, a ne od dimenzionalnosti transformisanog prostora.

4.6 SMO algoritam

4.6.1 Motivacija

Rešavanje dualnog optimizacionog problema iz sekcije 4.3 zahteva upotrebu numeričkih QP solvera. Međutim, standardni QP solveri postaju nepraktični za veće skupove podataka jer zahtevaju formiranje i čuvanje Gram matrice $\mathbf{K} \in \mathbb{R}^{m \times m}$, čiji su elementi $K_{ij} = K\left(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}\right)$. Za skup podataka sa m primera, memorijski zahtev raste kao $O(m^2)$, što za milione primera postaje računski neizvodljivo.

Upravo iz tog razloga, John Platt je 1998. godine predložio algoritam **sekvencijalne minimalne optimizacije** (*Sequential Minimal Optimization*, SMO), koji je danas standardni metod za treniranje SVM modela u većini biblioteka mašinskog učenja [Platt, 1998].

4.6.2 Osnovna ideja

Osnovna ideja SMO algoritma zasniva se na dekompoziciji originalnog optimizacionog problema na niz minimalnih podproblema. Umesto simultanog optimizovanja svih m Lagranževih multiplikatora, u svakom koraku se biraju **tačno dva multiplikatora** α_ii α_j, dok se svi ostali drže fiksnim. Za ova dva multiplikatora problem se rešava **analitički**, bez potrebe za numeričkim QP solverom.

Razlog zašto se biraju tačno dva, a ne jedan multiplikator, leži u ograničenju dualnog problema:

$$\sum_{i=1}^{m} \alpha_i \, y^{(i)} = 0.$$

Promena vrednosti jednog multiplikatora uz fiksiranje svih ostalih neizbežno bi narušila ovo ograničenje. Istovremenom promenom dva multiplikatora suprotnih klasa moguće je zadovoljiti ograničenje u svakom koraku.

4.6.3 Izbor multiplikatora

SMO koristi dve heuristike za efikasan izbor para multiplikatora u svakom koraku.

Prva heuristika odnosi se na izbor prvog multiplikatora α_i. Algoritam se fokusira na primere kod kojih α_i nije ni 0 ni C, jer su oni najčešće u stanju narušavanja KKT uslova. Ovi primeri nazivaju se nevezanim primerima (non-bound subset). Algoritam naizmenično prolazi kroz sve primere i kroz nevezani podskup, i staje kada više nijedan primer ne krši KKT uslove.

Druga heuristika odnosi se na izbor drugog multiplikatora α_j, i zasniva se na maksimizaciji veličine koraka koji se pravi pri ažuriranju. Budući da je računanje tačnog maksimalnog koraka skupo, Platt predlaže aproksimaciju: bira se α_j za koji je

$|E_i - E_j|$ maksimalno, gde je $E_k = h(\mathbf{x}^{(k)}) - y^{(k)}$ greška klasifikacije za primer k.

4.6.4 Analitičko rešenje za par multiplikatora

Nakon izbora para (α_i, α_j), novo optimalno α_j izračunava se kao:

$$\alpha_j^{\text{novo}} = \alpha_j^{\text{staro}} + \frac{y^{(j)}(E_i - E_j)}{\eta},$$

gde je:

$$\eta = K(\mathbf{x}^{(i)}, \mathbf{x}^{(i)}) + K(\mathbf{x}^{(j)}, \mathbf{x}^{(j)}) - 2K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}).$$

Dobijeno α_j^{novo} ograničava se na interval $[L, H]$ kako bi bili zadovoljeni box constraint uslovi, pri čemu su granice određene kao:

$$\text{ako } y^{(i)} \neq y^{(j)}: \; L = \max(0, \alpha_j - \alpha_i), H = \min(C, C + \alpha_j - \alpha_i);$$
$$\text{ako } y^{(i)} = y^{(j)}: \; L = \max(0, \alpha_i + \alpha_j - C), H = \min(C, \alpha_i + \alpha_j),$$

Nakon toga, novo α_i izračunava se kao:

$$\alpha_i^{\text{novo}} = \alpha_i^{\text{staro}} + y^{(i)} y^{(j)} (\alpha_j^{\text{staro}} - \alpha_j^{\text{novo}}).$$

Ovaj postupak ponavlja se sve dok svi Lagranževi multiplikatori ne zadovolje KKT uslove u okviru zadate tolerancije, čime je garantovana konvergencija ka optimalnom rešenju.

4.7 Zaključci o SVM metodologiji

Prvo, SVM ne minimizuje samo grešku na skupu za obučavanje, već i direktno kontroliše grešku generalizacije, što ga teorijski utemeljuje bolje od većine empirijskih klasifikatora.

Drugo, zahvaljujući kernel triku, SVM efikasno radi u visokodimenzionalnim i beskonačnodimenzionalnim prostorima, pri čemu računska složenost ne zavisi od dimenzionalnosti transformisanog prostora već od broja vektora.

Treće, rešenje SVM-a je retko u smislu da ga određuje samo mali podskup primera. Ovo čini model otpornim na šum u podacima koji su daleko od granice odluke i efikasnim pri klasifikaciji novih primera.

Konačno, izbor odgovarajućeg kernela i podešavanje hiperparametara C i γ ostaju ključni praktični izazovi pri primeni SVM-a. Standardni pristup je sistematska pretraga po mreži sa unakrsnom validacijom, kojom se pronalaze vrednosti hiperparametara koje minimizuju grešku generalizacije na datom skupu podataka.

5 Primena klasifikacionih metoda na problem detekcije lažnih transakcija kreditnim karticama

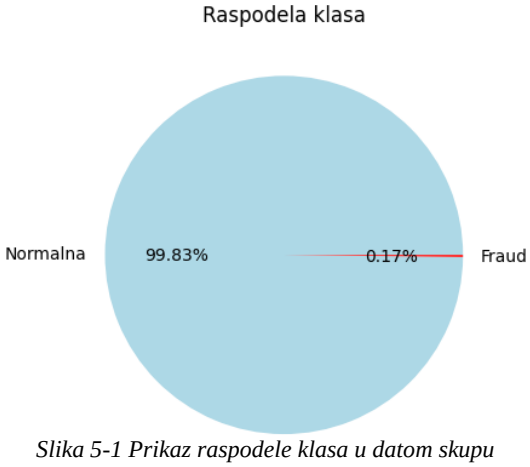
5.1 Opis problema i skupa podataka

U eksperimentalnom delu rada razmatran je problem detekcije lažnih transakcija kreditnim karticama, koji predstavlja tipičan problem binarne klasifikacije sa izrazito neuravnoteženim klasama. Zadatak modela je da, na osnovu dostupnih obeležja transakcije, odredi da li je transakcija legitimna ili lažna. Praktični značaj ovog problema je velik- pravovremeno otkrivanje prevare štiti korisnike od finansijskih gubitaka, a bankama smanjuje troškove.

U ovom radu korišćen je javno dostupan skup podataka Credit Card Fraud Detection, dostupan na platformi Kaggle. Skup podataka sadrži 284.807 transakcija kreditnim karticama izvršenih tokom dva dana u septembru 2013. godine od strane evropskih korisnika. Svaka transakcija opisana je sa 31 obeležjem: 28 anonimizovanih numeričkih obeležja (*V1–V28*) dobijenih primenom analize glavnih komponenti (PCA) na originalne podatke, obeležjem *Amount* koje predstavlja iznos transakcije u evrima, kao i kolonom *Time* koja predstavlja vreme mereno od prve transakcije. Kolona *Time* je uklonjena pre analize (obrazloženje u sekciji 5.2.1). Ciljna promenljiva *Class* uzima vrednost 0 za legitimne (normalne) i vrednost 1 za lažne transakcije.

Skup podataka karakteriše izrazita neuravnoteženost klasa- od ukupno 284.807 transakcija, samo 492 su označene kao lažne, što čini svega 0.17% ukupnog broja transakcija.

Na slici 5-1 prikazana je raspodela klasa u skupu podataka. Ovakva raspodela klasa predstavlja tipičan izazov u problemima detekcije anomalija i zahteva posebnu pažnju pri izboru metoda i metrika evaluacije. Tačnost (engl. *accuracy*) nije pogodna metrika u ovom slučaju, jer model koji bi uvek predviđao legitimnu transakciju postigao bi tačnost od 99.83%, a pritom ne bi otkrio nijednu prevaru. Zbog toga su u ovom radu korišćene metrike preciznost (engl. *precision*), odziv (engl. *recall*), F1-score i ROC-AUC.



Slika 5-1 Prikaz raspodele klasa u datom skupu podataka

Zbog anonimizacije primenom PCA, obeležja V1–V28 nemaju semantičko značenje, tj. ne znamo šta konkretno svako od njih predstavlja. To onemogućava primenu domenskog znanja pri odabiru obeležja i znači da klasifikator mora da uči isključivo iz statističkih obrazaca u podacima, bez mogućnosti da npr. izdvoji „sumnjivu lokaciju" ili „neobično veliki iznos" kao posebno važna obeležja. Sa jedne strane, to čini problem čistijim jer sve metode rade na ravnopravnim uslovima. Dok sa druge, ograničava interpretabilnost rezultata.

5.2 Priprema podataka

5.2.1 Predobrada

Pre treniranja modela izvršena je predobrada skupa podataka. Proverom je utvrđeno da skup ne sadrži nedostajuće vrednosti ni u jednoj koloni. Kolona *Time*, koja predstavlja broj sekundi proteklih od prve transakcije u skupu, uklonjena je iz analize, jer ne nosi prediktivnu vrednost već opisuje samo redosled transakcija unutar konkretnog dvodnevnog snimka, a ne karakteristike same transakcije.

Razlog je i praktičan: model koji bi naučio da klasifikuje po vremenskom rasporedu transakcija u ta dva konkretna dana bio bi beskoristan na novim podacima iz drugog perioda. Zadatak je naučiti šta karakteriše lažnu transakciju, a ne kada se ona desila.

5.2.2 Podela na skup za obučavanje i skup za testiranje

Skup podataka podeljen je u odnosu 80:20 na skup za obučavanje (227.845 transakcija) i skup za testiranje, tj. za evaluaciju performansi napravljenog modela (56.962 transakcije). Pri podeli je korišćen parametar *stratify* kako bi se osiguralo da oba skupa sadrže istu proporciju lažnih transakcija (0.17%). Bez stratifikovanog uzorkovanja moglo bi doći do situacije u kojoj jedan od skupova sadrži nesrazmerno mali ili veliki broj primera manjinske klase, što bi negativno uticalo na treniranje i evaluaciju modela.

Ovo je posebno važno kod ovako neuravnoteženih skupova, jer bez stratifikacije postoji realna mogućnost da test skup sadrži svega nekoliko desetina ili čak nula lažnih transakcija, što bi evaluaciju učinilo besmislenom.

5.2.3 Skaliranje

SVM metoda je osetljiva na razmere obeležja, jer se oslanja na rastojanja između tačaka u feature prostoru. Obeležje *Amount* ima vrednosti u rasponu od 0 do 25.691 evra, dok anonimizovana obeležja *V1–V28* imaju vrednosti u rasponu od oko -3 do 3. Bez skaliranja, obeležje *Amount* bi dominiralo pri računanju rastojanja i model ne bi mogao ispravno da nauči granicu odluke.

Zbog toga je primenjena standardizacija pomoću klase *StandardScaler*, kojom svako obeležje dobija srednju vrednost 0 i standardnu devijaciju 1 prema formuli:

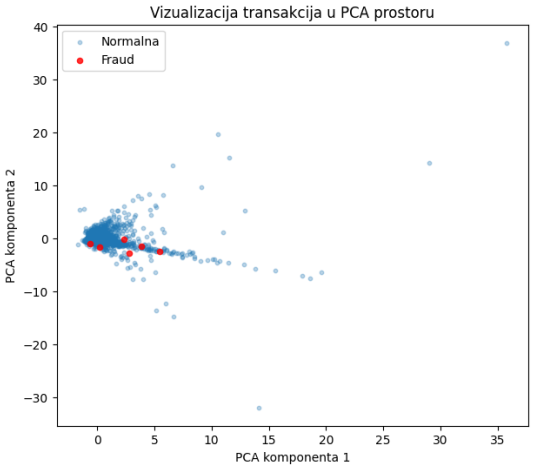
$$z = \frac{x - \mu}{\sigma}.$$

Važno je napomenuti da je *StandardScaler* fitovan isključivo na skupu za obučavanje, a zatim primenjen na oba skupa. Fitovanje na celom skupu podataka predstavljalo bi tzv. curenje podataka (engl. *data leakage*) i model bi indirektno video informacije iz test skupa tokom treniranja, što bi dalo lažno optimistične rezultate evaluacije.

5.3 Vizualizacija podataka

Kako bi se stekao uvid u strukturu podataka i prirodu problema, primenjena je analiza glavnih komponenti (PCA) radi redukcije dimenzionalnosti sa 30 na 2 dimenzije. Na slučajnom uzorku od 5.000 transakcija, prve dve PCA komponente zajedno objašnjavaju svega 12.16% ukupne varijanse (6.87% i 5.28% redom). Ovako nizak procenat objašnjene varijanse govori o tome da se informacija o transakcijama ravnomerno raspoređuje duž mnogo više od dve dimenzije, što otežava vizuelno razdvajanje klasa.

Na slici 5-2 prikazana je vizualizacija transakcija u dvodimenzionalnom PCA prostoru. Lažne transakcije (označene crvenom bojom) vidno se preklapaju sa legitimnim transakcijama (označene plavom bojom). Ovo potvrđuje da problem nije linearno separabilan u originalnom prostoru obeležja i motiviše primenu kernelskih metoda, posebno RBF kernela, koji podatke projektuje u prostor veće dimenzionalnosti u kome mogu biti separabilni.



Slika 5-2 Vizualizacija transakcija u PCA prostoru. Lažne transakcije (crveno) se preklapaju sa legitimnim (plavo), što ukazuje na složenost problema.

Ovo je važna napomena za tumačenje rezultata: vizuelno preklapanje klasa u 2D prostoru ne znači da su klase neseparabilne u punom 30-dimenzionalnom prostoru obeležja. PCA redukcija na dve dimenzije zadržava samo 12.16% varijanse, što znači da 87.84% informacije o podacima nije prikazano. Upravo zato KNN, koji radi direktno u punom prostoru, može da iskoristi strukturu koja u 2D vizualizaciji nije vidljiva.

5.4 Implementacija i opis klasifikacionih modela

U cilju analize problema detekcije lažnih transakcija, implementirano je pet klasifikacionih modela. Pored tri varijante SVM klasifikatora, primenjeni su i klasifikator sa Bajesovim kriterijumom minimalne cene i algoritam *k* najbližih suseda (*KNN*), kako bi se problem klasifikacije neuravnoteženog skupa podataka što bolje rešio.

5.4.1 Linearni SVM klasifikator

Linearni SVM klasifikator izabran je kao osnovni model zbog svoje jednostavnosti i interpretabilnosti. Ovaj model pretpostavlja linearnu separabilnost podataka i predstavlja dobru početnu tačku za poređenje sa složenijim modelima. Ovaj model implementiran je pomoću klase LinearSVC iz biblioteke *scikit-learn*. Za razliku od klase SVC, klasa LinearSVC koristi algoritam *LIBLINEAR* koji je znatno brži na velikim skupovima podataka i pogodan je za skup sa skoro 228.000 primera.

Kako bi se kompenzovala neuravnoteženost klasa, korišćen je parametar *class_weight="balanced"*, koji automatski povećava težinu lažnih transakcija obrnuto proporcionalno njihovoj učestalosti. Bez ovog parametra, model bi tendencijski uvek predviđao legitimnu transakciju jer time minimizuje ukupan broj grešaka.

5.4.2 RBF SVM klasifikator

Kako podaci u realnim problemima često nisu linearno separabilni, primenjen je i drugi model koji koristi RBF kernel (*Radial Basis Function*). Ovaj model podatke implicitno projektuje u beskonačnodimenzionalni prostor, omogućavajući nelinearnu granicu odluke. Implementiran je pomoću klase SVC sa parametrom *kernel="rbf*".

Zbog kvadratne računske složenosti $O(n^2)$ do $O(n^3)$ algoritma *LIBSVM* koji SVC koristi, treniranje na celom skupu za obučavanje nije bilo izvodljivo. Stoga je primenjena stratifikovana slučajna selekcija 50.000 primera iz skupa za obučavanje, pri čemu je sačuvana proporcija lažnih transakcija.

Za oba modela korišćen je parametar regularizacije C, koji čini kompromis između širine margine i greške klasifikacije. Kod RBF modela, dodatno je korišćen i parametar *gamma* koji određuje uticaj pojedinačnih trening primera.

5.4.3 Linearni SVM sa SMOTE balansiranjem

Treći model kombinuje linearni SVM klasifikator sa tehnikom SMOTE (*Synthetic Minority Oversampling Technique*) za balansiranje klasa. Ovaj model sam izabrala kao treći kako bi se ispitalo da li balansiranje klasa može poboljšati performanse nad manjinskom klasom. SMOTE sintetički generiše nove primere manjinske klase tako što za svaku lažnu transakciju pronalazi *k* najbližih suseda iz iste klase i interpolacijom kreira nove, veštački generisane primere u feature prostoru.

Primenom SMOTE na skup za obučavanje, broj lažnih transakcija povećan je sa 394 na 227.451, čime su klase potpuno izjednačene. Budući da SMOTE već balansira klase, parametar *class_weight* nije korišćen kod ovog modela. Važno je napomenuti da je SMOTE primenjen isključivo na skup za obučavanje, a skup za testiranje ostao je neizmenjen kako bi evaluacija bila realna.

Ovo je konzistentno sa teorijskim očekivanjem: SMOTE sintetički generiše nove primere interpolacijom između postojećih lažnih transakcija u prostoru obeležja. Međutim,

lažne transakcije su po prirodi problema atipične i retke, pa interpolacija između njih ne mora da generiše primere koji odgovaraju realnim prevarama. Pored toga, linearna granica odluke ostaje ograničenje bez obzira na balansiranje, tj. SMOTE ne menja geometrijsku prirodu problema.

5.4.4 Klasifikator sa Bajesovim kriterijumom minimalne cene

Osnovna ideja ovog pristupa je da različite vrste grešaka imaju različitu cenu- u kontekstu detekcije prevara, propuštena prevara (lažno negativan rezultat) znatno je skuplja od lažne uzbune (lažno pozitivan rezultat). Bajesov kriterijum minimalne cene formalizuje ovu asimetriju kroz odnos cena $\frac{C_{FN}}{C_{FP}}$, gde C_{FN} označava cenu lažno negativnog, a C_{FP} cenu lažno pozitivnog ishoda.

Umesto standardnog praga odluke od 0.5, klasifikacija se vrši prema pravilu: transakcija se klasifikuje kao lažna ukoliko važi $P(fraud|x) \geq \frac{1}{1+\frac{C_{FN}}{C_{FP}}}$.

Kao polazna osnova za klasifikaciju korišćene su stvarne učestalosti klasa iz skupa za obučavanje, odnosno $P(fraud) \approx 0.0017$ i $P(normalna) \approx 0.9983$, što odražava realnu neuravnoteženost podataka. Testirana je serija odnosa cena $\frac{C_{FN}}{C_{FP}} \in \{1, 2, 5, 10, 20, 50, 100, 200, 500\}$, a optimalan odnos određen je maksimizacijom F1 skora na fraud klasi test skupa.

5.4.5 KNN klasifikator

Kao dodatna metoda bez pretpostavki o distribuciji podataka, implementiran je algoritam k najbližih suseda (K-Nearest Neighbors, KNN). Za razliku od SVM-a i Bajesovog klasifikatora, KNN ne konstruiše eksplicitnu granicu odluke već svrstava novi primer u klasu koja dominira među njegovim k najbližim susedima u prostoru obeležja, mereno Euklidskim rastojanjem.

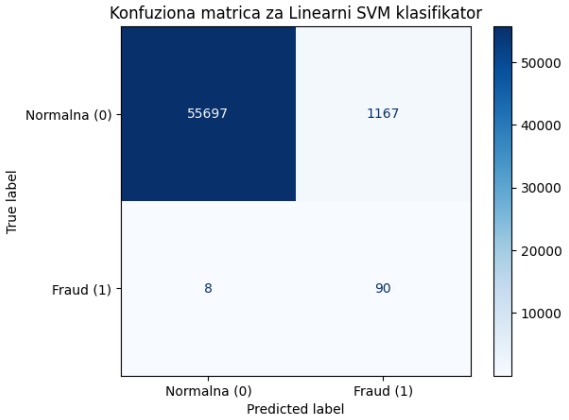
Zbog računske složenosti KNN-a na velikom skupu podataka, model je treniran na istom podskupu od 50.000 primera koji je korišćen i za RBF SVM, pri čemu je sačuvana originalna proporcija klasa stratifikovanim uzorkovanjem. Korišćeno je težinsko glasanje proporcionalno rastojanju (weights="distance"), kojim bliži susedi imaju veći uticaj na odluku- što je posebno pogodno za neuravnotežene skupove podataka jer smanjuje uticaj udaljenih primera većinske klase. Optimalna vrednost k određena je pretragom po vrednostima $k \in \{5, 11, 21, 51\}$, pri čemu je kao kriterijum korišćen F1 skor na fraud klasi.

Ipak, ovaj zaključak treba uzeti sa rezervom. Trening skup od 50.000 primera je slučajno odabran podskup i lokalna struktura oko pojedinih lažnih transakcija direktno zavisi od toga koji legitimni primeri su se našli u blizini u konkretnom uzorku. Različiti slučajni podskupovi mogu dati različite rezultate, što će biti razmotreno u analizi rezultata u poglavlju 6.

6 Rezultati

6.1 Linearni SVM klasifikator

Konfuziona matrica linearnog SVM klasifikatora prikazana je na slici 6-1. Od 98 lažnih transakcija u test skupu, model je ispravno identifikovao 90, dok je 8 propustio (lažno negativni). Međutim, model je pogrešno označio 1.167 legitimnih transakcija kao lažne (lažno pozitivni).



Slika 6-1 Konfuziona matrica linearnog SVM klasifikatora

Metrike evaluacije za fraud klasu prikazane su u tabeli 6-1. Odziv od 0.9184 znači da je model uhvatio 91.84% svih lažnih transakcija, što je visoka vrednost. Međutim, preciznost od svega 0.0716 govori da je od svih transakcija koje je model označio kao lažne, samo 7.16% zaista lažno, a ostatak su lažne uzbune. ROC-AUC vrednost od 0.9795 ukazuje na to da model dobro rangira transakcije po riziku.

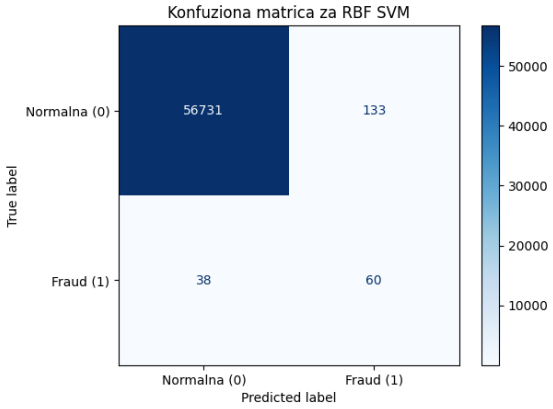
Tabela 6-1 Izveštaj o klasifikaciji za linearni SVM klasifikator

Klasa	Preciznost	Odziv	F1-score
Normalna (0)	0.9999	0.9795	0.9896
Fraud (1)	0.0716	0.9184	0.1328
Tačnost			**0.9794**

Ovakav rezultat je karakterističan za linearne modele primenjene na visoko neuravnotežene skupove uz agresivno ponderisanje klasa. Model pomera granicu odlučivanja duboko u region legitimnih transakcija da bi uhvatio što više prevara, ali po cenu velikog broja lažnih uzbuna. Operativno, 1.167 lažnih uzbuna na 56.962 transakcija znači da bi tim za prevare morao ručno da proveri svaku 49. transakciju. U sistemu koji obrađuje milione transakcija dnevno, to je neodrživo.

6.2 RBF SVM klasifikator

Konfuziona matrica RBF SVM klasifikatora prikazana je na slici 6-2. Model je ispravno identifikovao 49 od 98 lažnih transakcija, uz svega 53 lažno pozitivna rezultata.



Slika 6-2 Konfuziona matrica RBF SVM klasifikatora

U tabeli 6-2 data je evaluacija RBF modela, koji postiže znatno bolju preciznost (0.4804) u poređenju sa linearnim modelom, uz odziv od 0.5000. F1-score od 0.4900 je viši od ostala dva SVM modela (linearni i SVM+SMOTE), što ukazuje na bolji balans između preciznosti i odziva. Treba imati u vidu da je ovaj model treniran na manjem podskupu podataka (50.000 primera), što ograničava njegovu sposobnost učenja.

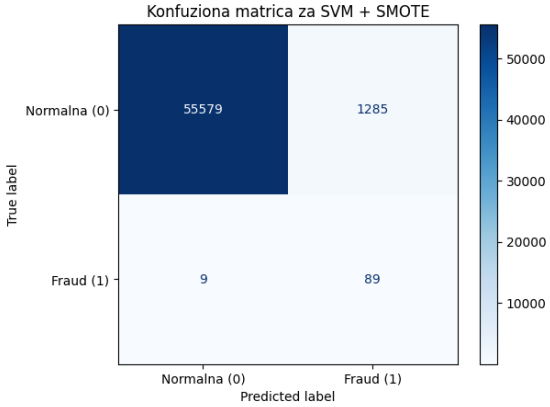
Tabela 6-2 Izveštaj o klasifikaciji za RBF SVM klasifikator

Klasa	Preciznost	Odziv	F1-score
Normalna (0)	0.9991	0.9991	0.9991
Fraud (1)	0.4804	0.5000	0.4900
Tačnost			**0.9982**

Znatno bolja preciznost RBF modela direktna je posledica nelinearne granice odluke. Lažne transakcije u ovom skupu podataka verovatno nisu linearno separabilne od legitimnih u originalnom prostoru obeležja, pa linearni model mora da bude previše konzervatan da bi ih uhvatio. RBF kernel implicitno projektuje podatke u prostor veće dimenzionalnosti gde je ta separacija moguća. Ipak, važno je napomenuti da je model treniran na svega 50.000 od 227.845 dostupnih primera, što znači da rezultati nisu nužno reprezentativni za ceo skup podataka. Treniranje na punom skupu je ostavljeno za dalji rad.

6.3 SVM + SMOTE klasifikator

Konfuziona matrica SVM + SMOTE klasifikatora prikazana je na slici 6-3. Model je ispravno identifikovao 89 od 98 lažnih transakcija, uz 1.285 lažno pozitivnih rezultata- nešto više nego kod linearnog SVM modela.



Slika 6-3 Konfuziona matrica SVM + SMOTE klasifikatora

Metrike ovog modela, prikazane u tabeli 6-3, su veoma slične linearnom SVM klasifikatoru- visok odziv (0.9082) uz nisku preciznost (0.0648). SMOTE balansiranje u ovom slučaju nije dovelo do značajnog poboljšanja u odnosu na pristup sa class_weight="balanced".

Tabela 6-3 Izveštaj o klasifikaciji za SVM + SMOTE klasifikator

Klasa	Preciznost	Odziv	F1-score
Normalna (0)	0.9998	0.9774	0.9885
Fraud (1)	0.0648	0.9082	0.1209
Tačnost			**0.9773**

Sličnost između linearnog SVM sa ponderisanjem klasa i linearnog SVM sa SMOTE balansiranjem nije iznenađujuća. Oba pristupa koriste linearnu granicu odluke u istom prostoru obeležja, a jedina razlika je u tome kako se ta granica uči. Ponderisanje klasa kaznama koriguje gradijent tokom optimizacije, dok SMOTE dodaje sintetičke primere koji fizički pomeraju granicu. Krajnji efekat je sličan: granica se pomera u korist manjinske klase, ali ostaje linearna. Razlika između dva pristupa bila bi izraženija sa nelinearnim kernelom.

6.4 Klasifikator sa Bajesovim kriterijem minimalne cene

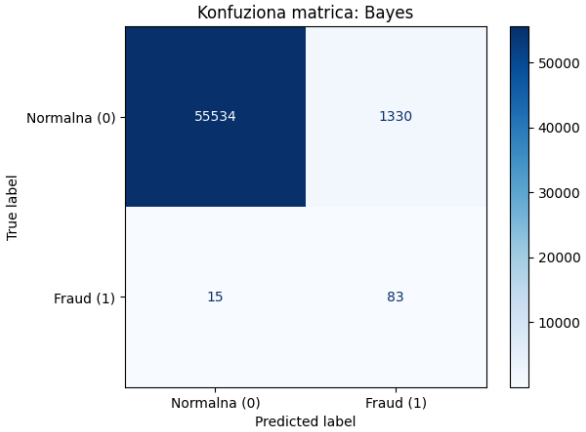
Bajesov klasifikator ispitan je pretragom po nizu odnosa cena $\frac{C_{FN}}{C_{FP}} \in \{1, 2, 5, 10, 20, 50, 100, 200, 500\}$. Za svaki odnos cena izračunat je odgovarajući prag odlučivanja, a optimalna vrednost određena je maksimizacijom F1 skora na fraud klasi test skupa. Rezultati pretrage prikazani su u Tabeli 6-4.1.

Tabela 6-4.1 Pretraga optimalnog praga odlučivanja za Bajesov kriterijum minimalne cene

C_FN/C_FP	Prag	Preciznost	Odziv	F1	TP	FP	FN
1	0.5000	0.0587	0.8469	0.1099	83	1330	15
2	0.3333	0.0580	0.8469	0.1086	83	1348	15
5	0.1667	0.0569	0.8469	0.1066	83	1376	15
10	0.0909	0.0565	0.8571	0.1060	84	1403	14
20	0.0476	0.0554	0.8571	0.1041	84	1432	14
50	0.0196	0.0547	0.8673	0.1030	85	1468	13
100	0.0099	0.0545	0.8776	0.1026	86	1493	12
200	0.0050	0.0538	0.8776	0.1014	86	1512	12
500	0.0020	0.0524	0.8776	0.0989	86	1556	12

Kao što tabela pokazuje, povećanje odnosa cena spušta prag odlučivanja i povećava odziv, ali uz konstantan pad preciznosti i F1 skora. Model sa $\frac{C_{FN}}{C_{FP}}$ = 500 hvata 86 od 98 prevara, ali generiše 1556 lažnih uzbuna- više nego prethodna dva modela. Razlog leži u prirodi Bajesovog klasifikatora: pomeranje praga ne menja kako model vidi podatke, već samo koliko je spreman da klasifikuje primer kao prevaru. Kada je prag blizu nule, onda je i svaka transakcija označena kao sumnjiva.

Optimalan odnos cena pokazao se kao $\frac{C_{FN}}{C_{FP}}$ = 1, što odgovara standardnom pragu od 0.5. Ovo je pomalo neočekivan rezultat, intuitivno bi se očekivalo da veće penalizovanje propuštenih prevara dovede do boljeg modela, ali F1 skor konzistentno opada sa porastom odnosa cena, jer porast odziva nije dovoljno velik da nadoknadi drastičan pad preciznosti. Napomenimo da su razlike u F1 skoru između različitih odnosa cena vrlo male (red veličine 0.01), što znači da je izbor optimalnog odnosa osetljiv na slučajne fluktuacije i da praktično nijedan odnos cena ne donosi suštinsko poboljšanje.



Slika 6-4 Konfuziona matrica *Bajesov klasifikator (optimalni prag = 0.5)*

Konfuziona matrica za optimalni prag prikazana je na Slici 6-4. Od 98 lažnih transakcija u test skupu, model je ispravno identifikovao 83, dok je 15 propustio. Međutim, pogrešno je označio 1330 legitimnih transakcija kao lažne.

Najneočekivaniji rezultat u ovoj tabeli je da optimalni odnos cena iznosi $\frac{C_{FN}}{C_{FP}} = 1$, što odgovara standardnom pragu od 0.5, bez ikakve korekcije za asimetričnost grešaka. To znači da Bajesov klasifikator u ovoj konfiguraciji ne donosi kvalitativno bolji rezultat od linearnog SVM-a sa standardnim pragom. Objašnjenje leži u tome što Bajesov kriterijum ovde ne menja sam model već samo prag odlučivanja na osnovu verovatnoća koje daje linearni SVM.

Metrike ovog modela, prikazazane su u tabeli 6-4.2.

Tabela 6-4.2 Izveštaj o klasifikaciji za Bajesov klasifikator (optimalni prag = 0.5)

Klasa	Preciznost	Odziv	F1-score
Normalna (0)	0.9997	0.9761	0.9878
Fraud (1)	0.0587	0.8469	0.1099
Tačnost			**0.9759**

6.5 KNN klasifikator

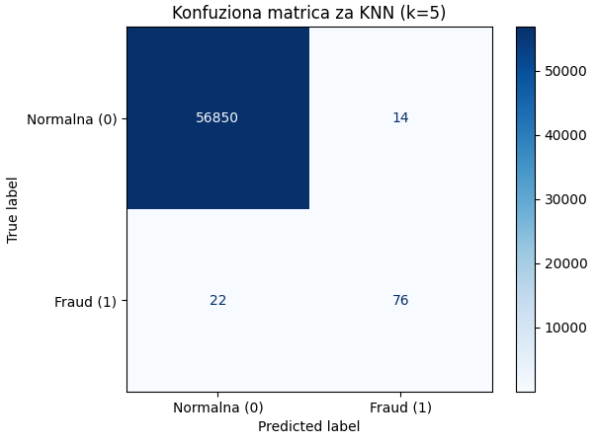
KNN klasifikator treniran je na stratifikovanom podskupu od 50.000 primera iz skupa za obučavanje, pri čemu je sačuvana originalna proporcija lažnih transakcija. Isti podskup korišćen je i za RBF SVM, što omogućava direktno poređenje ta dva modela pod jednakim uslovima. Optimalna vrednost k određena je pretragom po $k \in \{5, 11, 21, 51\}$, maksimizacijom F1 skora na fraud klasi test skupa. Rezultati su prikazani u Tabeli 6-5.

Tabela 6-5 Rezultati pretrage po k KNN

k	Preciznost	Odziv	F1
5	0.8444	0.7755	0.8085
11	0.8222	0.7551	0.7872
21	0.8132	0.7551	0.7831
51	0.8095	0.6939	0.7473

Odabrana je vrednost $k = 5$ koja daje najbolji F1 = 0.8085. Obrazac je jasan: sa porastom k i preciznost i odziv opadaju, što sugeriše da lažne transakcije u ovom skupu podataka imaju izraženu lokalnu strukturu- grupišu se blizu jedne druge u prostoru obeležja i da manji k bolje iskorišćava tu strukturu.

Konfuziona matrica za $k = 5$ prikazana je na Slici 6-5, a detaljan izveštaj o klasifikaciji dat je u Tabeli 6-6. Od 98 lažnih transakcija u test skupu, model je ispravno identifikovao 76, dok je 22 propustio. Broj lažnih uzbuna iznosi svega 14 što je daleko manje nego kod bilo kog drugog modela u ovom radu.



Slika 6-5 Konfuziona matrica za KNN klasifikator (k=5)

Tabela 6-6 Izveštaj o klasifikaciji za KNN klasifikator

Klasa	Preciznost	Odziv	F1-score
Normalna (0)	0.9996	0.9998	0.9997
Fraud (1)	0.8444	0.7755	0.8085
Tačnost			**0.9994**

Ovakav rezultat zaslužuje pažljivu interpretaciju. Sa jedne strane, postoji smisleno objašnjenje zašto KNN može biti dobar na ovom skupu: PCA vizualizacija u 2D prostoru pokazuje preklapanje klasa, ali to ne znači da je situacija ista u punom 30-dimenzionalnom prostoru. KNN koji radi direktno u tom prostoru može da iskoristi lokalnu strukturu- grupišu blizinu lažnih transakcija koja globalnim modelima kao što su SVM i Bajesov klasifikator nije vidljiva.

Sa druge strane, postoje ozbiljni razlozi za oprez. Model je treniran na slučajno odabranom podskupu od 50.000 od 227.845 primera, od čega je samo oko 394 lažnih transakcija. KNN klasifikuje svaki novi primer na osnovu njegovih lokalnih suseda u trening skupu, što znači da je rezultat direktno zavisan od toga koji primeri su se slučajno našli u tom podskupu. Drugi slučajni podskup mogao bi dati znatno drugačiju lokalnu strukturu oko pojedinih lažnih transakcija i time drugačije rezultate. Pored toga, obeležja V1–V28 su već rezultat PCA transformacije i implicitno ortonormalna, što pogoduje Euklidskom rastojanju kao meri sličnosti- u skupovima podataka bez takve strukture KNN bi mogao da pokaže znatno lošije performanse. Sve ovo sugeriše da bi robustnost ovih rezultata trebalo potvrditi ponovljenim eksperimentima sa različitim slučajnim podskupovima i unakrsnom validacijom, što prevazilazi okvire ovog rada.

ROC-AUC od 0.9182 nešto je niži od SVM modela, što znači da *KNN* nešto lošije rangira transakcije po riziku kada se gleda celokupan spektar pragova. Međutim, na standardnom pragu od 0.5, *KNN* postiže daleko bolji praktični rezultat od svih ostalih modela.

6.6 Uporedno poređenje modela

Tabela 6-7 prikazuje metrike evaluacije za fraud klasu za sva tri modela.

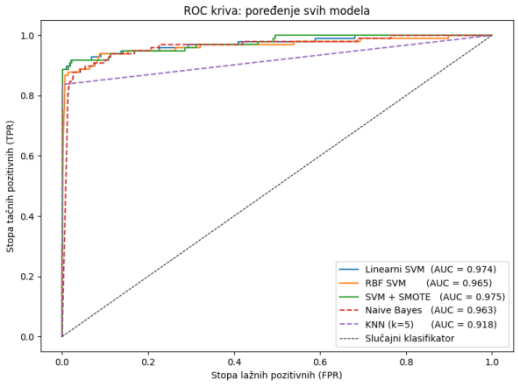
Tabela 6-7 Poređenje performansi svih modela na test skupu

Model	Preciznost	Odziv	F1-score	ROC-AUC
Linearni SVM	0.0716	0.9184	0.1328	0.9740
RBF SVM	0.4804	0.5000	0.4900	0.9650
SVM + SMOTE	0.0648	0.9082	0.1209	0.9750
Bajesov (C=1)	0.0587	0.8469	0.1099	0.9630
KNN (k=5)	0.8444	0.7755	0.8085	0.9182

ROC kriva grafički prikazuje odnos između stope tačno prepoznatih lažnih transakcija i stope pogrešno označenih legitimnih transakcija kao lažnih, za sve moguće pragove odluke

klasifikatora. Površina ispod ROC krive (ROC-AUC) sumira ovu informaciju u jednom broju između 0 i 1, gde vrednost 1 označava savršen klasifikator, a vrednost 0.5 odgovara nasumičnom pogađanju. ROC kriva za svih pet modela prikazana je na Slici 6-6.

Sve krive su daleko iznad dijagonale nasumičnog klasifikatora, što potvrđuje da svi modeli imaju stvarnu prediktivnu moć. Tri SVM modela i Bajesov klasifikator grupišu se u intervalu AUC = 0.963–0.975, dok KNN neznatno zaostaje sa AUC = 0.918. Međutim, AUC govori samo o tome koliko dobro model rangira transakcije po riziku- ne govori šta se dešava na konkretnom pragu odlučivanja koji se koristi u praksi.



Slika 6-6 Prikaz ROC krive svih 5 realizovanih modela

Na standardnom pragu od 0.5 slika je potpuno drugačija. KNN dominira po svim metrikama koje su operativno važne: F1 skor od 0.8085 višestruko je viši od bilo kog drugog modela, a broj lažnih uzbuna iznosi svega 14 naspram 1330 kod linearnog SVM-a i Bajesovog klasifikatora. Cena tog rezultata je niži odziv- KNN propušta 22 od 98 prevara, dok linearni SVM propušta samo 8.

Ograničenja eksperimenta koja treba imati na umu: RBF SVM i KNN su oba trenirana na podskupu od 50.000 primera, što ih stavlja u nejednake uslove u poređenju sa linearnim modelima koji su koristili ceo trening skup. Pored toga, KNN rezultati su potencijalno osetljivi na konkretan slučajni podskup, što znači da bi ponovljeni eksperiment mogao dati drugačije rezultate. Za potpuno fer poređenje svih pet modela bila bi potrebna unakrsna validacija na celom skupu podataka za sve modele, što je zbog računskih ograničenja ostavljeno za dalji rad.

Izbor modela stoga direktno zavisi od poslovnih prioriteta. Dva scenarija se jasno razlikuju. Ukoliko je prioritet ne propustiti nijednu prevaru, na primer u sistemima gde je svaka propuštena prevara direktan finansijski udar za banku, pogodniji su linearni SVM ili SVM + SMOTE koji postižu odziv iznad 0.90, uz svesno prihvatanje velikog broja lažnih uzbuna koje tim za prevare mora ručno da proveri. Ukoliko je prioritet minimizovati lažne uzbune i ne opterećivati operativni tim nepotrebnim proverama, jedini model koji to postiže na prihvatljiv način je KNN, sa F1 skorom od 0.8085 i samo 14 lažnih uzbuna na celom test skupu.

7 Zaključak

Ovaj rad bavio se problemom detekcije lažnih transakcija kreditnim karticama, koji je poslužio kao praktičan okvir za poređenje pet klasifikacionih metoda: tri varijante SVM-a, Bajesovog klasifikatora sa kriterijem minimalne cene i algoritma k najbližih suseda. Pokazalo se da nijedna od ispitanih metoda nije univerzalno najbolja i da svaka pravi drugačiji kompromis između broja uhvaćenih prevara i broja lažnih uzbuna i taj kompromis je u osnovi poslovne odluke, a ne tehničke.

Neuravnoteženost klasa bila je centralni izazov kroz ceo rad. Sa svega 0.17% lažnih transakcija, skup podataka kažnjava svaki model koji previše gleda na ukupnu tačnost. Linearni SVM i SVM + SMOTE nose se s tim tako što agresivno klasifikuju sumnjive transakcije i postižu odziv iznad 0.90, ali uz cenu od preko 1.200 lažnih uzbuna na test skupu. Bajesov klasifikator, uprkos eksplicitnom podešavanju praga prema odnosu cena grešaka, ponaša se gotovo identično i ne donosi kvalitativno bolji rezultat. Sva tri modela traže globalnu linearnu granicu u prostoru obeležja i čini se da takva granica jednostavno nije dovoljna za ovaj problem.

Najbolji praktični rezultat pokazao je KNN. Sa svega 14 lažnih uzbuna i F1 skorom od 0.8085, pokazao se kao daleko najprecizniji model u praksi, i to bez ikakvih pretpostavki o obliku granice odluke. Razlog verovatno leži u tome što lažne transakcije u ovom skupu imaju izraženu lokalnu strukturu u punom prostoru obeležja, tj. grupišu se blizu jedne druge što KNN direktno iskorišćava. RBF SVM je obećavajući ali nepotpuno istražen, pošto je zbog računskih ograničenja treniran na petini podataka, pa je teško reći koliko su njegovi rezultati reprezentativni.

Ako bih morala da preporučim jedan model za praktičnu primenu, odgovor zavisi od konteksta. Za sistem koji ne sme da propusti prevaru- linearni SVM. Za sistem gde svaka lažna uzbuna košta vreme i poverenje korisnika- KNN. To nije nedostatak istraživanja već njegova suština: ne postoji jedan tačan odgovor, postoji kompromis koji svaka organizacija mora da donese sama, na osnovu sopstvenih prioriteta.

Za dalji rad bilo bi zanimljivo ispitati da li RBF SVM treniran na punom skupu podataka premašuje KNN, kao i da li kombinovanje više modela u ansambl može da sačuva visok odziv uz istovremeno smanjenje broja lažnih uzbuna. Takođe bi bilo zanimljivo ispitati KNN sa različitim slučajnim podskupovima trening skupa kako bi se procenila varijansa njegovih rezultata i utvrdilo da li su performanse konzistentne ili zavise od konkretnog uzorka.

8 Literatura

[1] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.

[2] Kowalczyk, A. (2017). *Support Vector Machines Succinctly*. Syncfusion.

[3] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

[4] Dal Pozzolo, A., Caelen, O., Le Borgne, Y. A., Waterschoot, S., & Bontempi, G. (2015). Learned lessons in credit card fraud detection from a practitioner perspective. *Expert Systems with Applications*, 41(10), 4915–4928.

[5] Elkan, C. (2001). The foundations of cost-sensitive learning. *Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence*, 973–978.

[6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21–27.

[7] Platt, J. C. (1998). Sequential minimal optimization: A fast algorithm for training support vector machines. Microsoft Research Technical Report MSR-TR-98-14.

[8] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[9] Đurović, Ž. (2024). *Prepoznavanje oblika - materijali sa predavanja*. Elektrotehnički fakultet, Univerzitet u Beogradu.

[10] Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5.

[11] ULB Machine Learning Group. (2018). *Credit Card Fraud Detection* [Dataset]. Kaggle. https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud